

K-CMAS: 한국문화 멀티모달 질의응답을 위한 다중 에이전트 시스템

허인범, 정상근[†]
 충남대학교 컴퓨터공학과
 {inbum10222, hugmanskj}@gmail.com

K-CMAS: K-Culture Multi-Agent System for Multimodal Question Answering

Inbum Heo, Sangkeun Jung[†]
 Department of Computer Science and Engineering, Chungnam National University

요약

문화 기반 멀티모달 질의응답은 시각 정보뿐 아니라 문자 정보, 외부 지식, 문화적 맥락을 함께 활용해야 하며, 문항 유형에 따라 요구되는 추론 과정과 출력 조건도 달라진다. 본 연구에서는 이러한 복합적인 요소들을 기능별로 분해하고, 기존 범용 및 특화 모델의 서로 다른 능력을 역할에 따라 조합하는 K-Culture Multi-Agent System(K-CMAS)을 제안한다. K-CMAS는 여러 모델의 답안을 후보로 구성한 뒤, 선다형, 단답형, 서술형에 특화된 에이전트를 통해 필요한 정보 탐색과 추론 및 검증을 수행하고, 확보된 근거를 바탕으로 최종 답안을 선택한다. 국립국어원 AI말평 “한국문화 멀티모달 질의응답” 평가 데이터에서 K-CMAS는 선다형 93.49, 단답형 83.50, 서술형 39.84, 종합 72.28점을 기록하며 공식 리더보드 1위를 달성하였다. 또한 문항 특성에 따라 필요한 정보 탐색과 추론 기능을 선택적으로 적용하는 것이 추가적인 성능 향상에 기여함을 확인하였다. 이러한 결과는 복합적인 멀티모달 질의응답에서 단일 모델의 성능뿐만 아니라, 문제를 기능별로 분해하고 모델별 강점을 역할에 따라 활용하는 시스템 설계가 효과적임을 보여준다.

주제어: 한국문화 멀티모달 질의응답, 비전-언어 모델, 다중 에이전트 시스템

1. 서론

대규모 비전-언어 모델의 발전으로 이미지와 자연어를 이해하고 추론하는 능력이 크게 향상되었다 [1]. 이에 따라 멀티모달 질의응답은 이미지에 직접 드러난 정보를 식별하는 것을 넘어, 시각 정보와 외부 지식, 맥락을 함께 활용하여 답을 도출하는 문제로 확장되고 있다 [2].

문화 기반 멀티모달 질의응답은 이러한 종합적 이해가 요구되는 대표적인 영역이다. 문화적 대상의 의미는 시각적 정보뿐 아니라 언어, 역사, 관습, 사회적 맥락과 결합되어 형성되기 때문이다. 따라서 이미지를 인식하는 데 그치지 않고, 시각적 단서를 특정 문화권의 배경지식이나 외부 사실 정보와 연결하여 해석해야 한다. 그러나 기존 비전-언어 모델의 학습 데이터는 영어권과 서구 문화에 편중되어 있으며 [3], 언어와 문화권이 달라질 때 범용 모델의 성능이 저하되는 한계가 보고되어 왔다 [4].

이러한 문제의식에 따라 다양한 문화권을 대상으로 모델의 문화적 이해를 평가하는 벤치마크가 제안되어 왔다. 한국어와 한국문화 지식을 평가하는 벤치마크인 CLiCk가 제안되었으며 [5], K-Viscuit는 한국문화 이미지를 활용한 멀티모달 평가로 범위를 확장하였다 [6]. 최근 국립국어원 AI말평에서는 이미지와 한국어 질문을 바탕으로 선다형, 단답형, 서술형 답안을 생성하는 “한국문화 멀티모달 질의응답” 과제를 제시하였다.

그림 1은 각 문항 유형의 예시를 보여준다.

본 과제는 문항에 따라 요구되는 정보와 처리 방식이 다르며, 이를 세 가지 측면으로 정리할 수 있다. 첫째, **정보 요구의 다양성**으로, 문항에 따라 이미지의 대상이나 문자를 파악하거나 외부 사실 정보를 활용해야 한다. 둘째, **문항 유형의 차이**로, 선다형, 단답형, 서술형은 서로 다른 추론 과정과 출력 조건을 요구한다. 셋째, **문화적 맥락의 결합**으로, 시각적 단서를 한국 문화의 배경지식과 맥락에 연결하여 해석해야 한다.

이러한 문제를 해결하기 위한 방법으로는 모델 학습, 검색 증강 생성(Retrieval-Augmented Generation, RAG)을 통한 외부 지식 활용, 다중 모델 앙상블, 에이전트 기반 추론 등이 있다. 그러나 문항마다 필요한 정보와 출력 조건이 달라, 개별 모델이나 고정된 처리 절차만으로 모든 문항에 대응하는 데에는 한계가 있다. 이에 본 연구는 문제 해결 과정을 기능별로 분해하고, 기존 범용 및 특화 모델의 서로 다른 능력을 역할에 따라 조합하는 K-Culture Multi-Agent System(K-CMAS)을 제안한다.

K-CMAS는 여러 모델의 답안을 활용하여 문항 특성에 맞는 추론과 검증을 수행하고 최종 답안을 선택하는 다중 에이전트 시스템이다. 전체 과정은 **다중 모델 후보 구성**, **문항 유형별 추론 및 검증**, **근거 기반 최종 선택**의 세 단계로 이루어진다.

먼저 여러 모델이 동일한 문항에 대해 독립적으로 답안을 생성하여 후보를 구성한다. 다음으로 문항 유형별 추론 및 검증 단계에서는 선다형, 단답형, 서술형의 특성에 맞는 서로 다른 문제 해결 절차를 적용하고, 각 문항에 필요한 정보와 추론 기

[†]교신저자 (Corresponding Author)

선다형	단답형	서술형
 질문 다음 사진 속 음식의 이름은 무엇인지 고르시오. ① 평양냉면 ② 함흥비빔냉면 ③ 함흥물냉면 ④ 평양비빔냉면 ⑤ 정답 없음 정답 ① 평양냉면	 질문 사진 속 물건의 이름을 3음절로 답하시오. 정답 표주박	 질문 사진 속 기구의 명칭과 기능을 서술하시오. 정답 물레방아는 물의 힘으로 바퀴를 돌려 곡식을 찧거나 뿔는 기구이다.

그림 1. 2026년 국립국어원 인공지능(AI) 말뚱 “한국문화 멀티모달 질의응답” 과제의 문항 예시

능을 선택적으로 활용한다. 마지막으로 근거 기반 최종 선택 단계에서는 유형별 에이전트가 확보한 근거를 바탕으로 대안 후보를 평가하고, 이미지, 질문 및 외부 정보가 충분히 뒷받침하는 답안을 최종적으로 선택한다. 이를 통해 K-CMAS는 다중 모델의 답안과 유형별 추론 및 검증 결과를 단계적으로 결합한다.

K-CMAS는 공식 리더보드에서 **1위**를 기록하였다. 공식 평가 데이터에서 선다형 93.49, 단답형 83.50, 서술형 39.84, 종합 72.28점을 달성하였으며, 이는 한국문화 특화 모델인 Webs-Sejong의 종합 56.55점보다 15.73점 높은 성능이다.

기능별 효과 분석에서도 문항 특성에 맞는 정보 탐색과 추론 기능의 효과를 확인하였다. 특히 단답형은 기본 구성의 61.54점에서 선택적 지식 검색을 적용하여 71.15점으로 향상되었으며, 저신뢰 문항에 선택적 재추론을 추가한 구성에서는 75.00점을 기록하였다. 이러한 결과는 복합적인 멀티모달 질의응답에서 개별 모델의 성능뿐 아니라, 문항의 요구에 따라 필요한 기능을 구분하고 적절한 모델과 도구를 역할별로 활용하는 시스템 설계가 효과적임을 보여준다.

2. 관련 연구

외부 지식 활용 멀티모달 추론 멀티모달 질의응답에서는 이미지에 직접 나타난 정보뿐 아니라 이미지 내 문자와 외부 지식을 활용하는 방법이 연구되어 왔다. TextVQA는 이미지 내 문자 정보를 활용하는 질의응답을 다루었으며 [7], OK-VQA는 이미지 외부의 지식을 요구하는 질의응답을 제시하였다 [8]. 또한 검색을 통해 외부 지식을 결합하거나 시각적 관찰과 지식 추론을 분리하는 접근이 제안되었으며, 생성된 멀티모달 응답을 사실 단위로 분해하여 검증하는 연구도 이루어지고 있다 [9].

다중 모델 및 에이전트 추론 최근 단일 모델을 넘어 여러 모델과 외부 도구를 추론에 활용하는 접근이 연구되고 있다. ReAct는 추론 과정과 외부 도구 사용을 결합하는 방식을 제안하였으며 [10], Mixture-of-Agents(MoA)는 여러 모델의 출력을 단계적으로 활용하는 다중 모델 추론 구조를 제시하였다 [11]. 이러한 연구는 단일 모델에 의존하기보다 서로 다른 모델과 도구의 기능을 추론 과정에서 조합하는 방향으로 확장되고 있다.

본 연구는 한국문화 멀티모달 질의응답의 정보 요구와 문항 유형에 맞춰 외부 지식 활용과 다중 모델 및 에이전트 추론을 결합하여 최적화한다.

3. 한국문화 멀티모달 질의응답 과제

3.1 과제 개요

국립국어원 AI말뚱의 “한국문화 멀티모달 질의응답” 과제는 이미지와 한국어 질문을 입력으로 받아 한국문화에 관한 답안을 생성하는 과제이다. 입력 이미지는 한국어 텍스트를 포함하거나 한국문화와 관련된 내용을 담고 있으며, 평가 범위는 전통 의례, 복식, 유물, 유적뿐 아니라 현대의 생활양식, 제도, 공간, 공공서비스 등 폭넓은 문화 영역을 포함한다.

문항은 선다형, 단답형, 서술형으로 구분되며, 전체 데이터는 학습 데이터 1,000문항, 검증 데이터 200문항, 공식 평가 데이터 800문항으로 구성된다. 학습 데이터는 선다형 518문항, 단답형 254문항, 서술형 228문항이며, 공식 평가 데이터는 각각 415문항, 206문항, 179문항으로 구성된다.

3.2 과제의 주요 특성

본 과제의 특성은 크게 세 가지 측면으로 정리할 수 있다.

정보 요구의 다양성 문항에 따라 이미지 속 대상이나 문자를 직접 파악하는 것부터 장소, 기관, 제도 등의 외부 사실 정보




그림 2. K-CMAS 전체 구조

를 확인하는 것까지 요구되는 정보가 다양하다. 따라서 하나의 정보 원천만으로 모든 문항을 처리하기 어렵다.

문항 유형의 차이 선다형은 선택지 간 비교와 판단, 단답형은 정확한 정보 식별과 표면형 생성, 서술형은 여러 정보를 일관된 설명으로 구성하는 과정을 요구한다. 이처럼 문항 유형에 따라 필요한 추론 과정과 출력 조건이 서로 다르다.

문화적 맥락의 결합 문화 관련 문항은 이미지에 나타난 정보를 시각적으로 인식하는 것만으로 해결하기 어렵다. 이미지 속 객체와 문자를 한국문화의 맥락에서 해석하여 대상의 명칭과 기능, 대상 간 관계를 파악해야 한다.

또한 과제에서 제공하는 학습 데이터는 1,000문항으로 규모가 작아, 추가 학습에만 의존하기 어렵다는 제약이 있다.

4. K-CMAS: K-Culture Multi-Agent System

그림 2와 같이 K-CMAS는 문항마다 필요한 정보와 추론 방식이 다르다는 점을 고려하여 문제 해결 과정을 **다중 모델 후보 구성**, **문항 유형별 추론 및 검증**, **근거 기반 최종 선택**의 세 단계로 분리한다. 먼저 여러 모델이 독립적으로 생성한 답안을 후보로 구성하고, 문항 유형에 필요한 정보와 추론 기능을 활용하여 후보를 검증한다. 마지막으로 확보된 근거와 출력 조건을 종합하여 최종 답안을 결정한다.

4.1 다중 모델 후보 구성

본 단계에서는 특정 모델의 단일 예측에 의존하지 않고 다양한 답안 후보를 확보한다. 모델마다 강점을 보이는 문항과 오류

유형이 다를 수 있으므로, 여러 범용 및 특화 모델이 동일한 문항을 독립적으로 추론하여 서로 다른 답안 후보를 생성한다.

4.2 문항 유형별 추론 및 검증

문항 유형별 추론 및 검증 단계에서는 각 유형이 요구하는 정보와 문제 해결 과정의 차이를 반영한다. 각 에이전트는 모든 기능을 일괄적으로 적용하지 않고, 문항의 정보 요구에 따라 필요한 탐색과 검증 기능을 선택적으로 수행한다.

4.2.1 선다형 에이전트

선다형 에이전트는 **선택지 비교**와 **명제 검토** 기능을 수행한다. 선택지 비교 기능에서는 각 답안 후보를 이미지 및 질문과 개별적으로 대조하여 시각적, 의미적 근거를 확인한다. 명제 검토 기능에서는 답안 후보들의 핵심 명제를 검토하고, 질문의 긍정 또는 부정 조건, 복수 정답 여부, 선택지 형식 등을 함께 검사한다.

4.2.2 단답형 에이전트

단답형 에이전트는 문항의 정보 요구에 따라 **텍스트 인식**, **지식 검색**, **선택적 재추론** 기능을 수행한다. 텍스트 인식 기능은 이미지 내 문자가 정답 도출에 필요한 경우 해당 정보를 추출하여 답안 후보를 검증한다. 지식 검색 기능은 문화 지식이나 이미지 외부의 사실 정보가 필요한 경우 관련 정보를 탐색하고 답안 후보와의 일치 여부를 확인한다. 선택적 재추론 기능은 기존 후보와 확보된 정보만으로 답안을 결정하기 어려운 문항에 대해 추가적인 추론을 수행하여 대안 후보를 생성한다.

표 1. 방법별 성능 비교. 검증 점수는 3회 반복 추론의 평균($\pm$ 표본 표준편차), 공식 평가 점수는 리더보드 결과이다. 최고 성능은 굵게, 두 번째 성능은 밑줄로 표시하였다. ^{KC}는 한국문화 특화 모델을 의미한다.

방법	검증 데이터				공식 평가 데이터			
	선다형 Accuracy	단답형 Exact Match	서술형 ROUGE/BLEU	종합 평균	선다형 Accuracy	단답형 Exact Match	서술형 ROUGE/BLEU	종합 평균
직접 추론								
Kanana-V-3B	62.14 (± 0.00)	19.23 (± 0.00)	27.54 (± 0.00)	36.30 (± 0.00)	60.24	13.59	32.90	35.58
A.X-4.0-VL-Light	76.70 (± 0.00)	36.54 (± 0.00)	30.91 (± 0.00)	48.05 (± 0.00)	76.63	28.64	30.74	45.33
Qwen3-VL-8B	69.90 (± 0.00)	13.46 (± 0.00)	23.51 (± 0.00)	35.63 (± 0.00)	67.47	11.65	24.77	34.63
JGOS-31B-Citizen ^{KC}	<u>91.26</u> (± 0.00)	50.00 (± 0.00)	32.71 (± 1.64)	57.99 (± 0.55)	85.54	46.12	33.06	54.91
Joangju-KR-31B ^{KC}	90.94 (± 0.56)	52.56 (± 2.94)	33.48 (± 1.58)	58.99 (± 0.33)	<u>87.47</u>	47.57	34.00	56.35
Webs-Sejong-31B ^{KC}	89.32 (± 0.00)	50.64 (± 1.11)	<u>34.16</u> (± 1.02)	58.04 (± 0.09)	86.02	49.03	34.60	56.55
AI말평 학습 데이터 기반 학습								
Kanana-V-3B	62.14 (± 0.00)	28.85 (± 0.00)	27.54 (± 0.00)	39.51 (± 0.00)	60.00	27.18	32.90	40.03
A.X-4.0-VL-Light	76.70 (± 0.00)	41.03 (± 1.11)	30.91 (± 0.00)	49.55 (± 0.37)	76.63	32.52	30.74	46.63
Qwen3-VL-8B	69.90 (± 0.00)	14.10 (± 1.11)	28.79 (± 0.41)	37.60 (± 0.23)	71.81	14.56	30.54	38.97
JGOS-31B-Citizen	<u>91.26</u> (± 0.00)	25.00 (± 1.92)	32.71 (± 1.64)	49.66 (± 1.18)	85.54	30.58	33.06	49.73
외부 한국문화 자료 추가 학습								
Kanana-V-3B + K-Culture-Desc	74.76 (± 1.68)	30.77 (± 3.33)	23.17 (± 3.20)	42.90 (± 2.45)	70.60	25.73	28.45	41.60
Qwen3-VL-8B + K-Culture-Desc	73.46 (± 1.48)	14.74 (± 1.11)	29.50 (± 0.18)	39.23 (± 0.58)	73.98	15.53	30.45	39.99
RAG								
Qwen3.5-9B + AI말평 학습 데이터	70.87 (± 0.00)	23.08 (± 0.00)	31.03 (± 0.00)	41.66 (± 0.00)	69.88	14.56	33.12	39.19
Qwen3.5-9B + 한국어 위키백과	70.87 (± 0.00)	21.15 (± 0.00)	31.03 (± 0.00)	41.02 (± 0.00)	69.88	16.50	33.12	39.83
JGOS + 한국어 위키백과	<u>91.26</u> (± 0.00)	46.15 (± 0.00)	32.71 (± 1.64)	56.71 (± 0.55)	85.54	41.26	33.06	53.29
다중 모델 앙상블								
JGOS-Qwen-Kanana $\rightarrow$ Qwen	<u>91.26</u> (± 0.00)	50.00 (± 0.00)	27.54 (± 0.00)	56.27 (± 0.00)	85.54	<u>54.37</u>	32.90	57.60
JGOS-Joangju-Webs $\rightarrow$ JGOS	<u>91.26</u> (± 0.00)	<u>53.85</u> (± 0.00)	34.06 (± 0.00)	<u>59.72</u> (± 0.00)	86.51	53.88	<u>36.37</u>	<u>58.92</u>
다중 에이전트 시스템								
MoA	<u>91.26</u> (± 0.00)	<u>53.85</u> (± 0.00)	33.81 (± 0.00)	59.64 (± 0.00)	85.30	49.03	35.49	56.61
K-CMAS (Ours)	93.20 (± 0.00)	75.00 (± 0.00)	36.91 (± 0.00)	68.37 (± 0.00)	93.49	83.50	39.84	72.28

4.2.3 서술형 에이전트

서술형 에이전트는 학습 예시 활용과 사실 및 형식 검토 기능을 수행한다. 학습 예시 활용 기능에서는 입력 문항과 유사한 학습 데이터를 검색하고, 해당 질문과 답안을 모델에게 예시로 제공하여 답안의 내용과 형식을 참고하도록 한다.

사실 및 형식 검토 기능에서는 생성된 설명의 핵심 대상이 이미지와 일치하는지 확인하고, 각 내용이 이미지 또는 외부 정보에 의해 뒷받침되는지 검토한다. 또한 고유명사, 날짜, 수치의 근거를 확인하고, 출력 길이가 요구 조건을 충족하는지 검사하여 사실적 오류와 형식적 불일치를 줄인다.

4.3 근거 기반 최종 선택

마지막 단계에서는 유형별 에이전트가 확보한 정보와 검증 결과를 바탕으로 각 후보를 평가한다. 이후 근거가 충분하고 출력 조건을 만족하는 후보를 최종 답안으로 채택한다.

이와 같은 구조를 통해 K-CMAS는 문항의 정보 요구와 추론 과정에 따라 서로 다른 모델과 기능을 역할별로 활용한다.

5. 실험 및 결과 분석

검증 데이터 200문항에서 각 방법과 기능의 효과를 분석하고, 공식 평가 데이터 800문항에서 최종 성능을 평가하였다. 검증 및 공식 평가 데이터는 학습에 사용하지 않았다.

5.1 실험 설정

평가 지표 선다형은 Accuracy, 단답형은 Exact Match, 서술형은 ROUGE와 BLEU의 평균으로 평가하였으며, 종합 점수는 세 유형 점수의 평균으로 산출하였다.

모델 선정 비교 실험의 기본 모델로는 범용 VLM과 AI Hub 리더보드¹에서 높은 성능을 보인 한국문화 특화 모델(JGOS, Joangju-KR, Webs-Sejong)을 포함한 6개 VLM을 선정하였다. 각 비교 방법을 다양한 모델과 모델 조합에 적용하였으며, 주요 결과에는 대표 구성을 제시하였다.

¹<https://leaderboard.aihub.or.kr>




그림 3. 유형별 기능 누적 적용에 따른 성능 변화(검증 데이터). 빨간 점선은 적용 전 성능, 각 점은 누적 적용 성능, 화살표는 직전 단계 대비 변화량을 나타낸다.

학습 설정 AI말뭉 학습 데이터 기반 학습과 외부 한국문화 자료를 활용한 추가 학습에는 QLoRA를 적용하였다. 외부 자료를 활용한 추가 학습에서는 Qwen [12]과 Kanana를 대상으로 AI말뭉 학습 데이터와 K-Culture-Desc [13] 530문항을 결합한 1,530개 예제를 사용하였다. Qwen, Kanana, A.X [14]는 학습률 10^{-4} 와 LoRA rank 16을 사용하였으며, JGOS는 학습률 5×10^{-5} 와 LoRA rank 8을 사용하였다.

외부 지식 검색 설정 RAG는 AI말뭉 학습 질의응답 254쌍, 한국어 위키백과 문서 719,036개를 각각 검색 자료로 활용하여 실험하였다. 검색 단위는 별도의 청크 분할 없이 질의응답 쌍 또는 개별 문서로 구성하였다.

다중 모델 및 에이전트 시스템 설정 다중 모델 앙상블은 세 모델의 답안을 하드 보팅하고, 합의되지 않은 경우 지정된 모델로 재판정하였다. JGOS-Qwen-Kanana 조합은 Qwen을, JGOS-Joangju-Webs 조합은 JGOS를 재판정 모델로 사용하였다. 반면 MoA는 세 모델(JGOS, Joangju-KR, Webs-Sejong)의 답안을 후보로 구성하고, JGOS가 모든 문항에서 이를 검토·종합하여 최종 답안을 생성하는 구조로 구현하였다.

5.2 전체 성능 분석

표 1은 검증 데이터와 공식 평가 데이터에서 각 방법의 성능을 나타낸다. K-CMAS는 공식 평가 데이터에서 72.28점으로 모든 비교 방법 중 가장 높은 성능을 기록하였다. 특히 단답형에서 다른 방법들과 비교하여 높은 성능을 보였다.

직접 추론에서는 31B 규모의 한국문화 특화 모델이 전반적으로 높은 성능을 보였으나, 추가 학습의 효과는 모델과 문항 유형에 따라 일관되지 않았다. 예를 들어 JGOS는 학습 후 종합 성능이 57.99점에서 49.66점으로 감소하였으며, 외부 한국문화 자료를 추가한 경우에도 일부 유형에서 성능 저하가 나타났다.

RAG에서도 외부 지식의 추가가 일관된 성능 향상으로 이어지지 않았다. JGOS와 한국어 위키백과를 결합한 구성은 Qwen 기반 RAG보다 높은 성능을 보였지만, JGOS의 직접 추론 성능에는 미치지 못하였다. 이는 외부 정보를 제공하는 것뿐만

표 2. K-CMAS의 단계별 처리 과정과 수행 모델

단계	수행 작업	모델 및 구성
1. 다중 모델 후보 구성	직접 추론 후보	JGOS, Webs, Joangju, A.X
	학습 후보	Qwen3-VL, Kanana (QLoRA)
	앙상블 후보	JGOS-Joangju-Webs → JGOS
선다형 문항		
	선택지 비교	JGOS
	명제 검토	Qwen3.6-27B
단답형 문항		
2. 유형별 추론 및 검증	텍스트 인식	VARCO-OCR (1.7B)
	지식 검색	A.X + 위키백과
	선택적 재추론	A.X
서술형 문항		
	학습 예시 활용	JGOS + 학습 예시 3개
	사실 및 형식 검토	A.X + VARCO (14B)
3. 근거 기반 최종 선택		
	최종 답안 선택	A.X

아니라, 필요한 정보를 선별하고 적절한 추론 과정에서 활용하는 방식이 중요함을 시사한다.

다중 모델 앙상블과 MoA는 검증 데이터에서 각각 59.72점과 59.64점으로 성능을 소폭 향상시켰다. 반면 K-CMAS는 문항 유형과 정보 요구에 따라 필요한 모델과 기능을 구분하여 활용함으로써 모든 유형에서 최고 성능을 기록하였다. 이러한 결과는 여러 모델의 답안을 단순히 결합하는 것보다 문제를 기능별로 분해하고 모델별 강점을 역할에 따라 활용하는 시스템 설계가 효과적임을 보인다.

5.3 문항 유형별 기능 효과 분석

그림 3은 K-CMAS의 유형별 기능을 순차적으로 추가했을 때 검증 데이터에서 나타나는 성능 변화를 보여준다.

선다형에서는 선택지 비교와 명제 검토를 통해 성능이 91.26에서 93.20으로 향상되었다. 단답형은 텍스트 인식만으로는 변화가 없었지만, 지식 검색과 선택적 재추론을 통해 61.54에서 75.00까지 증가하였다. 서술형은 학습 예시 활용과 사실 및 형식 검토를 통해 35.57에서 36.91로 향상되었다.

이러한 결과는 각 에이전트의 기능이 문항 유형별로 서로 다른 오류와 정보 부족을 보완하며, K-CMAS의 성능 향상에 기여함을 보여준다.

5.4 기능별 수행 모델 분석

표 2는 K-CMAS의 단계별 기능과 수행 모델을 정리한 것이다. 다중 모델 후보 구성 단계에서는 범용 및 특화 모델의 직접 추론 답안, 추가 학습 모델의 답안, 다중 모델 앙상블 답안을 결합하여 후보 집합을 구성하였다. 각 기능의 수행 모델과 구성은 해당 기능에 적용했을 때의 검증 성능을 비교하여 선정하였다.

예를 들어 단답형의 선택적 재추론에서는 A.X를 적용한 구성이 75.00점을 기록하여 Qwen3.6-27B를 적용한 구성의 71.12점보다 높은 성능을 보였으며, 이에 A.X를 해당 기능의 수행 모델로 채택하였다.

5.5 오류 분석

K-CMAS의 검증 데이터 출력을 문항 유형별로 사후 분석하였다. 단답형에서는 ‘생치포’와 ‘좌등’ 같은 희귀 문화 명칭과 주소 및 기관명 식별에서 오류가 관찰되었다. 오류는 정답이 후보 집합에 포함되지 않은 경우와 정답에 해당하는 후보가 있었으나 최종 답안으로 선택되지 않은 경우로 구분되었다. 이는 후보 생성과 최종 선택이 각각 오류 발생 지점이 될 수 있음을 보여준다. 한편 선택적 재추론을 통해 초기 후보에 없던 정답이 추가된 사례도 확인되어, 추가 추론이 후보 생성의 한계를 보완할 수 있음을 확인하였다.

서술형에서는 패랭이를 삿갓으로, 정로대를 향로로 설명하는 대상 오인과 질문에서 요구한 정보의 누락이 관찰되었다. 이러한 오류는 핵심 대상의 식별과 요구 정보의 충족 여부를 함께 검증할 필요가 있음을 보여준다. 또한 의미상 적절한 답안이 낮은 점수를 받은 사례도 확인되었다. 이는 ROUGE와 BLEU 기반 평가에서 답안의 의미적 적절성과 어휘적 일치에 기반한 점수 사이에 차이가 발생할 수 있음을 시사한다.

6. 결론

본 연구에서는 한국문화 멀티모달 질의응답의 정보 요구와 문항 유형에 따라 여러 모델과 기능을 역할별로 활용하는 다중 에이전트 시스템 K-CMAS를 제안하였다. K-CMAS는 다중 모델 후보 구성, 문항 유형별 추론 및 검증, 근거 기반 최종 선택을 통해 문항에 필요한 정보와 추론 기능을 선택적으로 활용한다.

K-CMAS는 검증 및 공식 평가 데이터의 모든 문항 유형에서 직접 추론, 학습, RAG, 다중 모델 앙상블 및 MoA를 상회하였다. 공식 평가에서는 종합 72.28점으로 최고 직접 추론 모델보다 15.73점, 최고 다중 모델 앙상블보다 13.36점 높은 성능을 기록하였으며, 공식 리더보드 1위를 달성하였다. 특히 단답형에서 가장 큰 성능 차이를 보여 문항에 필요한 정보 탐색과 추가 추론의 효과를 확인하였다.

기능별 분석에서도 선택지 비교, 지식 검색, 선택적 재추론, 학습 예시 활용, 사실 및 형식 검토 등 문항 유형에 맞춘 기능이 성능 향상에 기여하였다. 이러한 결과는 여러 모델의 답안을 단순히 결합하는 것보다, 문제를 기능별로 분해하고 각 모델의 강점에 맞춰 역할을 배정하는 시스템 설계가 복합적인 멀티모달 질의응답에 효과적임을 보여준다.

이러한 기능별 설계는 문항 해결에 필요한 정보와 출력 조건을 기준으로 기존 모델과 도구를 배치하여 과제에 적합한

질의응답 시스템을 구성하는 데 활용할 수 있다. 또한 새로운 모델이나 지식원을 해당 기능에 연결함으로써 시스템을 보완하고 확장할 수 있다.

감사의 글

본 연구는 과학기술정보통신부 및 한국연구재단의 중견연구지원사업의 연구결과로 수행되었으며(RS-2025-0055621731482092640101), KRIBB 기관고유사업의 연구비 지원에 의해 수행되었음(KGM1062612).

참고문헌

- [1] H. Liu *et al.*, “Visual instruction tuning,” *Advances in Neural Information Processing Systems*, A. Oh *et al.*, Eds., Vol. 36, pp. 34 892–34 916, 2023.
- [2] D. Schwenk *et al.*, “A-okvqa: A benchmark for visual question answering using world knowledge,” *Computer Vision – ECCV 2022*, S. Avidan *et al.*, Eds., pp. 146–162, 2022.
- [3] S. Nayak *et al.*, “Benchmarking vision language models for cultural understanding,” *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, Y. Al-Onaizan, M. Bansal, and Y.-N. Chen, Eds., pp. 5769–5790, Nov. 2024.
- [4] D. Romero *et al.*, “Cvqa: Culturally-diverse multilingual visual question answering benchmark,” *arXiv preprint arXiv:2406.05967*, 2024.
- [5] E. Kim *et al.*, “Click: A benchmark dataset of cultural and linguistic intelligence in korean,” *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*, pp. 3335–3346, 2024.
- [6] C. Park *et al.*, “Evaluating visual and cultural interpretation: The k-viscuit benchmark with human-vlm collaboration,” *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pp. 21 960–21 974, 2025.
- [7] A. Singh *et al.*, “Towards vqa models that can read,” *2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 8309–8318, 2019.
- [8] K. Marino *et al.*, “Ok-vqa: A visual question answering benchmark requiring external knowledge,” *2019 IEEE/CVF conference on computer vision and pattern recognition (CVPR)*, pp. 3190–3199, 2019.
- [9] P. Sahu, K. Sikka, and A. Divakaran, “Pelican: Correcting hallucination in vision-LLMs via claim decomposition and program of thought verification,” *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, Y. Al-Onaizan, M. Bansal, and Y.-N. Chen, Eds., pp. 8228–8248, Nov. 2024.
- [10] S. Yao *et al.*, “React: Synergizing reasoning and acting in language models,” *arXiv preprint arXiv:2210.03629*, 2022.
- [11] J. Wang *et al.*, “Mixture-of-agents enhances large language model capabilities,” *International Conference on Learning Representations*, Y. Yue *et al.*, Eds., Vol. 2025, pp. 33 944–33 963, 2025.
- [12] S. Bai *et al.*, “Qwen3-vl technical report,” *arXiv preprint arXiv:2511.21631*, 2025.
- [13] “A korean cultural understanding benchmark dataset with detailed scenario,” 2025. [Online]. Available: <https://huggingface.co/datasets/SOGANG-ISDS/K-Culture-Desc>
- [14] S. A. M. Lab, “A.x 4.0 vl light,” 2025. [Online]. Available: <https://huggingface.co/skt/A.X-4.0-VL-Light>