

BitNet의 실험적 검증 및 BitNet 양자화를 적용한 BitCNN

허인범¹, 황태욱², 정상근²

충남대학교 천문우주학과¹, 컴퓨터공학과²

{inbum10222, taewook5295}@gmail.com, hugman@cnu.ac.kr

Experimental validation of BitNet and BitCNN with BitNet quantization

Inbum Heo¹, Taewook Hwang², Sangkeun Jung²

Department of Astronomy and Space Science¹, Computer Science & Engineering², Chungnam National University

요약

본 연구는 가중치를 1.58비트, Activation을 8비트로 양자화하는 BitNet 모델과 해당 양자화 기술을 CNN에 적용한 모델을 제안하며, 각 모델에 대한 실험적 검증을 수행한다. 이를 위해 1.58비트 양자화 기술을 합성곱에 적용한 BitConvolution을 제안한다. 검증을 위해 DNN, BitDNN, CNN, BitCNN 모델들의 정확도와 메모리할당량, 추론시간 비교 실험을 수행하였다. 또한 ResNet과 같은 큰 모델에 BitConvolution을 적용하여 동일한 방법으로 검증을 수행한다. BitCNN 모델에서의 정확도는 기존 CNN모델과 크게 차이가 나지 않는 결과를 보이지만, BitNet을 적용한 ResNet의 경우 다소 낮은 성능을 보였으며, BitNet이 주장하는 이점들을 실현하기에는 하드웨어 및 소프트웨어적인 한계가 존재한다.

1. 서론

최근 몇 년간 거대한 딥러닝 모델의 등장은 AI 기술의 비약적인 발전을 주도하고 있다. 그러나 이러한 거대 모델은 높은 계산 비용과 메모리 할당량을 요구한다. 특히, 모바일 및 임베디드 시스템에서는 제한된 자원에서 효율적인 실행의 중요성이 지속적으로 대두되고 있다.

이러한 문제에 대한 해결 방안으로 경량화 기술이 제안되었다. 경량화는 딥러닝 모델의 크기를 줄이고, 메모리 요구량을 감소시키며, 계산 비용을 낮추는 기술을 포함한다. 이 중에서도 양자화(quantization)는 딥러닝 모델의 가중치(weight)와 Activation을 낮은 비트 수로 표현하여 모델을 경량화하는 기술로 주목받고 있다. 양자화를 적용함으로써 일반적인 딥러닝 연산방식인 32비트 연산에 비해 모델의 메모리 사용량 및 에너지 소비를 줄일 수 있다.

[1, 2]에서는 추론 속도와 에너지효율성을 극대화시키며 모델의 정확도에 크게 영향을 끼치지않는 양자화 모델을 제시한다. 모델의 학습 가중치를 1.58비트로 양자화하기 위해 BitLinear를 사용하여, nn.Linear를 대체한다. [1, 2]에서는 Large Language Models (LLM)에 적용하여 실험을 진행하였다.

본 논문에서는 [1, 2]의 연구를 기반으로 가중치를 1.58비트로, 입력값을 8비트로 양자화하여 모델을 학습하는 실험을 진행한다. 우리는 [1, 2]에서 제시한 방법론에 기반하여 실험을 수행한다. 추가적으로 Convolutional Neural Networks (CNN)에 [1, 2]에서 제시한 방법론에 기반하여 양자화된 CNN 모델 학습이 가능한지 검증하고자 한다.

제시된 양자화 규칙에 따라 합성곱 계층(Convolutional layer)을 새롭게 정의하고 1.58비트로 양자화한 모델과 일반 모델 사이의 정확도와 메모리 효율을 비교하여 CNN 모델에서 1.58비트 양자화의 실현 가능성을 살펴본다.

2. 관련 연구

[3]는 가중치, 입력값 및 기울기를 양자화하여 학습하는 양자 신경망을 제시한다. 순전파 과정에서 양자신경망은 메모리크기와 처리량을 대폭 줄이고 산술연산을 비트 단위 연산으로 대체한다. [3]에서는 딥러닝에서 일반적으로 행렬의 곱 연산을 비트 단위의 XNOR 연산과 population count를 활용하여 연산을 대체한다. 이는 결과적으로 모델의 전력소비를 대폭 감소시킨다.

최근 모델을 낮은 비트 수의 정수형태로 양자화하는 방법이 많이 사용되고 있다. 하지만 이러한 방식의 모델을 양자화하는 방법에는 장단점이 존재한다. 우선 정수 형태로 양자화하여 모델을 학습시킨다면 메모리효율이 좋아지지만 정확도 측면에서 실수형 표현형식보다 성능이 저하되는 것을 볼 수 있다. [4]는 실수형으로 양자화 하는 모델과 정수형으로 양자화하는 모델 두 모델을 비교하는 실험을 수행하였다.

[1]은 가중치를 1비트로, 입력값을 8비트로 양자화하였다. [2]는 [1]과 모델구조는 동일하지만, Absmean Quantization Function를 적용하여 가중치를 1.58비트, (-1, 0, 1)로 양자화하였고, 입력값은 Absmax Quantization Function를 적용하여 8비트로 양자화하였다. 두 모델 모두 nn.Linear를 BitLinear로 대체한 Transformer기반의 BitNet 구조를 가지고있다. 우리는 1.58비트 양자화 알고리즘을 이용하여 CNN적용하고 더 나아가 ResNet[5]에 적용하여 성능을 평가한다.

[1, 2]에서는 행렬곱셈이 필요하지 않은 새로운 계산 패러다임을 제시했다. 하지만 행렬곱셈이 필요하지 않는 연산을 하기위해서는 1.58비트 단위의 양자화된 LLM에 최적화된 특별한 하드웨어가 필요하다고 주장한다.

최근의 연구에 따르면, LLM과 같은 거대한 모델에 양자화를 적용할 수 있는 적합한 하드웨어를 연구가 진행중이다[6].

표 1. 모델별 정확도 및 메모리 효율

		Accuracy	Training_Time	Testing_Time	Training_Memory	Testing_Memory
MNIST	DNN	0.981	2.265s	0.491s	435MiB	401MiB
	BitDNN	0.985	4.835s	0.739s	439MiB	405MiB
	CNN	0.995	4.788s	0.609s	711MiB	459MiB
	BitCNN	0.995	6.904s	0.8s	743MiB	504MiB
CIFAR10	DNN	0.495	2.153s	0.561s	455MiB	401MiB
	BitDNN	0.519	4.453s	0.796s	479MiB	443MiB
	CNN	0.847	4.503s	0.687s	803MiB	473MiB
	BitCNN	0.839	5.731s	0.829s	843MiB	503MiB
CIFAR100	DNN	0.22	2.083s	0.543s	479MiB	413MiB
	BitDNN	0.234	4.356s	0.794s	523MiB	449MiB
	CNN	0.596	9.875s	1.066s	2405MiB	1155MiB
	BitCNN	0.575	12.605s	1.422s	2657MiB	1013MiB

3. BitConvolution




그림 1. BitConvolution

우리는 [1, 2]에서 제안한 양자화 방법을 활용하여 CNN에 적용할 수 있는 BitCNN을 제안한다. 합성곱 계층에는 선형 계층과 다르게 입력값의 채널에 대한 고려가 필요하다. 우리는 입력값의 차원 형태를 저장하고 이를 토대로 양자화를 적용한 값의 차원을 재구성하였다. 또한 입력값의 채널에 해당하는 정보를 보존하기 위해 Channel-wise하게 양자화를 진행하였다. 모델은 Quantization Aware Training으로 학습과정에서 양자화하여 모델의 경량화를 진행하였다.

그림 1은 BitLinear와 Bitconvolution을 도식화한 그림이다. DNN 모델에 사용되는 1.58비트 양자화 알고리즘을 Convolution에 적용하여 Bitconvolution을 구성하였다.

그림 2는 BitConvolution의 연산과정을 보인다. 입력값의 차원 형태를 저장한 후 Channel-wise Quantization을 진행하였다. 메모리 할당량을 최소화 하기 위해서 형상 변화 함수로는 reshape 함수를 사용하였다.




그림 2. Channel-wise Quantization

4. 실험

본 실험은 [2]의 연구에 기반하여 가중치를 1.58비트로, 입력값을 8비트로 양자화하여 모델의 성능을 평가한다. 실험에 사용된 데이터는 MNIST, CIFAR10, CIFAR100 총 3개를 사용하였다.

실험에 사용된 모델은 Deep Neural Networks (DNN), BitLinear을 사용한 BitDNN, CNN, BitConvolution을 사용한 BitCNN으로 구성된 총 4개의 모델을 사용하였다. 배치 크기는 128로 고정하였고, 잠재 가중치에 대한 근소한 업데이트는 1.58비트로 양자화된 가중치에는 효과가 없다는 주장[1, 2]을 기반으로 학습률 (learning rate)을 높게 설정하였다. 옵티마이저로는 학습률이 4e-5인 AdamW를 사용하였다.

실험은 각각의 모델을 학습시킨 후 정확도를 측정하였다. 또한, 모델이 1회 학습할 때의 소요 시간과 메모리 사용량 그리고 1회 추론할 때의 소요 시간과 메모리 사용량을 측정하였다. 이를 통해 양자화된 모델의 성능과 메모리 효율을 기존 모델과 비교하는 실험을 수행한다.

표 1은 실험 결과로 기존 모델과 양자화된 모델간의 성능을 측정하였다. MNIST 데이터로 학습시킨 두 모델간의 성능은 거의 유사하지만 다른 실험결과는 편차가 있는 것으로 보인다. 하지

표 2. ResNet 모델 실험별 정확도 및 메모리 효율

CIFAR 100	ResNet18		ResNet34		ResNet50		ResNet101	
	CNN	BitCNN	CNN	BitCNN	CNN	BitCNN	CNN	BitCNN
Accuracy	0.623	0.398	0.519	0.37	0.518	0.356	0.533	0.37
Training Time	46.76s	63.410s	71.245s	96.089s	131.298s	210.512s	213.401s	329.101s
Testing Time	6.833s	8.210s	7.865s	11.122s	11.917s	22.574s	18.409s	32.393s
Training Memory	4845MiB	5745MiB	6139MiB	7657MiB	13049MiB	18309MiB	18287MiB	25877MiB
Testing Memory	1311MiB	1533MiB	1353MiB	1575MiB	2151MiB	2785MiB	2205MiB	2819MiB

만 CIFAR100을 추론데이터로 사용한 BitCNN에서 CNN보다 추론 시 메모리 할당량이 작은 것을 볼 수 있다.

두 번 째 실험으로는 합성곱의 양자화를 대규모 합성곱 신경망에 적용하여 수행하였다. 표 2는 합성곱 계층 개수에 따른 ResNet 모델을 구축하고 각각의 모델의 합성곱에 양자화를 적용하여 실험한 결과이다. 모델은 ResNet18, ResNet34, ResNet50, ResNet101 총 4개의 모델들과 양자화된 ResNet 모델들로, 총 8개의 모델을 사용하였다. 본 실험 결과는 기존의 ResNet 모델이 비교적으로 좋은 성능을 보인다.

[1, 2]에서 제시한 양자화 기술을 사용하여 모델을 양자화 하면 얻을 수 있는 기댓값으로는 연산량을 줄이고 메모리 효율을 높여, 추론 시간을 감소시킬 수 있다는 점이 있다. 하지만 추론 시 모델의 할당량이 기존의 모델보다 크고, 시간 단축이 발생하지 않는다.

5. 논의

본 연구에서는 [1, 2]에서 제시한 양자화 방법을 사용하여 합성곱 신경망 모델에 적용하고 이에 따른 실험을 진행하였다. 표 1의 실험 결과, 기존 모델과 양자화된 모델 간의 메모리 할당량 차이가 비교적 크게 나타난다. 다음은 이와 같은 실험 결과가 도출되는 원인을 분석한 결과이다.

양자화된 연산을 진행할 때 오버플로우가 발생하는 것을 실험적으로 확인하였다. 일반적인 딥러닝 모델의 연산은 GPU에서 실수 형태의 32비트 연산이 수행된다. 하지만 양자화된 모델은 보다 낮은 비트 연산이 필요하다. 본 실험에서는 저비트 연산을 수행하기 위해 CPU에서 추론을 진행하였다. 이 과정에서 양자화된 1.58비트 형태의 가중치와 8비트 입력값들의 연산을 수행할 때 오버플로우가 발생하는 것을 확인하였다.

합성곱의 특성을 고려한 양자화 기술을 적용하기 위해서는 형상 변환 함수를 사용해야 한다. 이 과정에서 추가적인 메모리가 할당되고 오버헤드가 발생하는 것으로 보여진다.

6. 결론

본 연구에서는 BitNet의 실험적 검증을 수행하고 양자화 기술을 활용하여 BitConvolution을 구현하여 BitCNN 모델에서

1.58비트 양자화의 가능성에 대해 검증하는 실험을 진행하였다. BitCNN 모델에서의 정확도는 기존 CNN 모델과 크게 차이가 나지 않는 결과를 보인다. 하지만 모델의 크기가 커질 수록 성능이 떨어지는 모습을 보인다. 또한 1.58비트 양자화 기술을 사용한 CNN 모델에서 오버헤드로 인하여 메모리 할당량이 기존 모델보다 크고, 연산과정에서 오버플로우가 발생하는 것을 확인했다. 따라서 현재 하드웨어 및 소프트웨어로는 1.58비트의 양자화 모델의 성능을 재현하는 것은 어려운 것으로 보인다.

참고 문헌

- [1] H. Wang, S. Ma, L. Dong, S. Huang, H. Wang, L. Ma, F. Yang, R. Wang, Y. Wu, and F. Wei, "Bitnet: Scaling 1-bit transformers for large language models," *arXiv preprint arXiv:2310.11453*, 2023.
- [2] S. Ma, H. Wang, L. Ma, L. Wang, W. Wang, S. Huang, L. Dong, R. Wang, J. Xue, and F. Wei, "The era of 1-bit llms: All large language models are in 1.58 bits," *arXiv preprint arXiv:2402.17764*, 2024.
- [3] I. Hubara, M. Courbariaux, D. Soudry, R. El-Yaniv, and Y. Bengio, "Quantized neural networks: Training neural networks with low precision weights and activations," *Journal of Machine Learning Research*, vol. 18, no. 187, pp. 1–30, 2018.
- [4] A. Kuzmin, M. Van Baalen, Y. Ren, M. Nagel, J. Peters, and T. Blankevoort, "Fp8 quantization: The power of the exponent," *Advances in Neural Information Processing Systems*, vol. 35, pp. 14651–14662, 2022.
- [5] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 770–778, 2016.
- [6] D. Ghimire, D. Kil, and S.-h. Kim, "A survey on efficient convolutional neural networks and hardware acceleration," *Electronics*, vol. 11, no. 6, p. 945, 2022.