

CNN기반 글자단위 오류 모방기를 활용한 OCR 후보정 데이터 생성

황태욱[°], 허인범, 정상근

충남대학교 컴퓨터공학과

{taewook5295[°], inbum10222}@gmail.com, hugman@cnu.ac.kr

Generating OCR Post-Correction Data via a CNN Based Character Level Error Simulator

Taewook Hwang[°], Inbum Heo, Sangkeun Jung

Computer Science & Engineering, Chungnam National University

요약

본 연구는 CNN 기반의 글자 단위 오류 모방기를 활용하여, 실제 OCR 시스템에서 발생하는 오류를 효과적으로 모사한 후보정 학습 데이터를 자동으로 생성하는 방법을 제안한다. 제안한 방법은 글자 이미지로부터 오류 가능성이 높은 대체 글자들을 예측하고, 이를 원문 텍스트에 적용하여 실제 OCR 오류와 유사한 형태의 오류 데이터를 생성한다. 생성된 데이터는 다양한 도메인의 문서에서 OCR 후보정 모델을 학습하는 데 활용되었으며, 기존 EasyOCR 및 PaddleOCR 결과 대비 각각 27%와 48%의 Character Error Rate(CER) 개선 효과를 나타냈다. 또한, 거대 언어 모델 기반의 후보정과 비교했을 때도 높은 정확도와 처리 효율성을 보였다. 제안된 접근법은 사람의 개입 없이도 고품질의 OCR 후보정 학습 데이터를 생성할 수 있어, OCR 후보정 성능 향상 및 데이터 구축 비용 절감에 실질적인 기여를 할 수 있다.

1. 서론

최근 대규모 언어 모델(Large Language Model, LLM)의 급속한 발전과 함께 멀티모달 인공지능 기술이 빠르게 성장하고 있으며, 이에 따라 이미지 기반 정보를 효과적으로 이해하는 능력이 점점 더 중요해지고 있다.

특히, 이미지 기반 데이터 중에는 스캔되거나 촬영된 보고서, 논문, 문제집, 간판, 메뉴판과 같은 텍스트 중심의 자료가 많아지고 있으며, 이러한 글자 이미지를 인식하는 광학문자인식(Optical Character Recognition, OCR) 기술은 핵심적인 역할을 수행한다.

초거대 모델인 ChatGPT와 같은 서비스는 높은 수준의 OCR을 수행할 수 있지만, 연산 자원이 많이 소모되고 비용이 높아 상용화에는 한계가 있다. 따라서 일반적인 상용 환경에서는 상대적으로 작은 OCR 모델들이 주로 사용되며, 이들 모델은 다양한 글자 이미지에 대해 인식률이 낮거나 오류가 발생하는 경우가 적지 않다. 특히, 이미지 품질이 낮아질수록 오류율은 더욱 높아진다.

이처럼 현존하는 OCR 시스템은 어느 정도의 인식 오류를 수반하며, 이러한 오류는 딥러닝 모델의 성능 저하나 OCR을 활용하는 상용 시스템의 오작동으로 이어질 수 있어 OCR 결과에 대한 후보정(post-correction) 과정이 필수적이다.

그러나 OCR 후보정을 위한 고품질 학습 데이터는 여전히 부족한 실정이다. 일부 연구에서는 정답 텍스트로부터 이미지를 생성한 후 OCR을 수행하여 데이터셋을 구성하거나 OCR의 오류 분포를 실험적으로 획득하여 활용하는 방법을 사용하지만, 생성된 데이터의 품질이 일관되지 않으며 시간도 많이 소요된다[1].

이에 본 연구에서는 Convolutional Neural Network (CNN) [2] 기반의 글자단위 오류 모방기를 활용하여 OCR 결과와 유사한

오류를 인위적으로 생성하고, 이를 통해 대규모 고품질의 OCR 후보정 학습 데이터를 효율적으로 구축하는 방법을 제안한다.

2. 관련 연구

OCR 후보정 데이터셋 생성을 위해 시도된 방법 중 대표적인 방법들은 다음과 같다.

무작위 오류 삽입 방식[3]은 깨끗한 텍스트 말뭉치에 정해진 비율로 문자 삽입, 삭제, 치환 오류를 임의로 주입하여 합성 데이터를 생성하는 가장 간단한 방식이다. 이 방식은 구현이 매우 간단하고 추가 자원이 필요 없어 널리 사용되지만, 실제 OCR 시스템의 오류 분포와는 괴리가 있다는 단점이 있다. 따라서 생성된 데이터가 현실성과는 거리가 멀 수 있으며, 학습된 모델이 실제 환경에서의 일반화 성능이 떨어질 수 있다.

이미지 생성 기반 방식[4]은 텍스트를 이미지로 렌더링한 뒤 다양한 노이즈를 추가하고, 이를 실제 OCR 시스템에 입력하여 오류가 포함된 텍스트를 얻는다. 이 방식은 실제 환경을 시뮬레이션하기 때문에 보다 현실적인 오류 패턴을 포함할 수 있으며, 이미지 기반 학습에도 적합하다. 그러나 OCR 시스템에 따라 생성된 오류의 양과 유형이 제한적일 수 있고, 높은 품질의 OCR 시스템을 사용할 경우 데이터에 충분한 오류가 포함되지 않을 수 있다. 또한 이미지 생성 및 처리에 상당한 계산 비용이 요구된다.

실제 오류 분포 기반 삽입 방식[5]은 동일 도메인의 텍스트를 OCR 처리하여 얻은 결과를 원문과 정렬한 후, 삽입, 삭제, 치환 오류의 확률 분포를 추출하는 방법이다. 이 분포를 기반으로 다른 깨끗한 말뭉치에 오류를 삽입하여 보다 현실적인 합성 데이터를 생성할 수 있다. 이 방법은 실제 오류 패턴을 반영한다는 점에서 학습 효율이 높지만, 합성에 활용할 추가적인 말뭉치와 정렬 알고리즘이 필요하다는 점에서 비용이 크고, 저자원 언어에는 적용이 어렵다는 한계가 있다.

본 연구는 과학기술정보통신부 및 한국연구재단의 중견연구지원사업의 연구결과로 수행되었음(RS-2025-0055621731482092640101)

표 1. OCR 오류 모방 데이터 및 OCR 수행 데이터 (‘.’는 띄어쓰기 오류를 의미함)

	Sentence 1	Sentence 2
Label	주로 푸젠성 남부와 광둥성 동부 출신들이 이주하였다.	이에 프랑스 함대가 대만 북부를 공격하면서 시작되었다.
Ours	주로 푸젠성 남부와 광 웅 성 동부 출신 들 이 이 주 하였다.	이에 프랑스 함대가 대만 북부를 공격하 면 사 시작되었다.
EasyOCR	주로 푸 제 성 남부와 광 둥 성 동부 출신들이 이주하였다.	이에 프랑스 함대가 대만 북부 를 공격하면서 시작되 었다 .
PaddleOCR	주로 푸젠성 남부 와 광둥성 동부 출신들이 이주하였다.	이에 프랑스 함대가 대만 북부를 공 격 하면서 시작되었다.

글리프 유사도 기반 오류 삽입 방식[1]은 문자 간 시각적 유사성을 정량화한 뒤, 유사도가 높은 문자 쌍을 중심으로 치환 오류를 주입하는 새로운 방식이다. 다양한 컴퓨터 비전 기반 특징 추출기를 활용하여 각 문자쌍의 유사도를 계산하고, Jaccard 지수와 평균 거리로 유사도를 정량화한다. 이 방식은 실제 OCR에서 발생하는 유사 글자 간 치환 오류를 효과적으로 모사할 수 있으며, 추가 말뭉치 없이도 고성능 합성 데이터 생성을 가능하게 한다. 그러나 문자 수가 많은 언어에서는 $O(n^2)$ 복잡도와 높은 계산 비용이 문제가 될 수 있다.

3. OCR 후보정용 학습 데이터 생성 방법

그림 1은 제안하는 방법을 도식화한 것으로, 글자 vocab으로부터 글자 이미지를 생성하여 오류 모방기를 학습하고, 이렇게 학습된 오류 모방기를 활용하여 OCR 오류를 흉내낸 문장을 생성하여 OCR 후보정 모델을 학습한다.

3.1 CNN기반 글자단위 OCR 오류 모방 모델

본 연구에서는 인위적으로 OCRed 오류가 포함된 데이터를 생성하기 위해 학습되지 않은 ResNet34[6] 모델을 활용하여 글자 인식기를 학습하였다.

ResNet34 모델은 입력받은 글자 이미지를 보고 어떤 글자인지 예측하는 방식으로 학습되었으며, 글자는 랜덤으로 1개에서 8개의 글자를 선정한 뒤 PIL 라이브러리를 활용하여 글자 이미지를 생성하여 학습 데이터로 활용하였다. 이 때 한국어, 중국어, 일본어, 영어를 모두 표기할 수 있는 공개된 7개의 폰트를 수집하여 매 생성마다 랜덤하게 활용하였다.

학습에 활용한 글자들은 숫자와 자주 활용되는 특수문자 일부(50글자), 알파벳(52글자), 한글자모(11,266글자), 히라가나와 가타카나(189글자), 한중일 통합한자(20,989글자)¹로 총 32,546글자를 활용하였다.

3.2 OCR 오류를 포함하는 데이터 생성

모델 학습이 완료된 후 학습에 활용한 32,546글자에 대한 모든 logits값을 구한 뒤, 각 글자별로 자기자신을 제외한 상위 5개의 확률을 갖는 글자를 선별하였으며, 이를 OCR 모델이 헛갈릴 수 있는 오류 데이터로 가정하였다. 이 때 특수문자는 모든 글자에서 선별되었으나 각 언어들은 각자의 언어 안에서 선별되었다.




그림 1. OCR 후보정 데이터 생성 파이프라인 (그림 상단의 샘플 결과물은 가독성을 위해 서로 다른 예제를 활용하였음.)

예를들어 한글인 ‘ㄱ’의 경우 상위 5개의 글자 중 한글이 아닌 다른 언어의 글자가 포함되었다면, 해당 글자를 제외하고 특수문자와 한글로만 상위 5개의 글자를 선별하였다.

학습 데이터는 AIHub의 한국어-다국어 번역 말뭉치 (인문학)[7]을 활용하였다. 해당 학습 및 검증 데이터셋은 해당 데이터셋에 있는 모든 글자를 10%의 확률로 선별된 5개의 오류 글자들과 치환하여 생성하였으며, 이 때 5개의 오류 글자들은 모델의 logits이 높은 순서대로 40%, 30%, 15%, 10%, 5%의 가중치를 주어 선택하였다. logits간의 편차가 굉장히 크게 발생하여 logits을 가중치로 직접 활용하지 않았다. 또한 10%확률로 띄어쓰기를 삽입하였으며, 기존에 있던 띄어쓰기는 1%의 확률로 삭제하였다.

표 1은 제안한 방법으로 생성된 데이터와 EasyOCR²과 PaddleOCR[8]을 수행한 결과이다. 실제 OCR 결과와 유사한 오류가 삽입된 것을 확인할 수 있으며, 일부 띄어쓰기가 삽입되거나 삭제된 것을 확인할 수 있다.

4. 실험

본 연구에서는 제안한 OCR 후보정 데이터 생성 방법의 실효성을 검증하기 위해 제안한 한국어 데이터셋으로 T5[9]모델을 학습한 뒤, 실제 OCR을 수행한 평가 데이터를 교정하여 Character Error Rate (CER) 개선을 확인하고자 하였다.

4.1 실험설계

실험에 사용된 데이터셋은 번역 데이터 중 한국어 데이터셋만을 활용하였으며, 생성한 학습 데이터 231,069문장과 검증 데이터 30,652문장, PaddleOCR과 EasyOCR 수행을 통해 획득한 평가

1) CJK Unified Ideographs

2) <https://github.com/JaidedAI/EasyOCR.git>

표 2. OCR 후보정 CER 성능

	OCR CER	Ours CER	ChatGPT 4o CER
EasyOCR	0.074	0.054(+27%)	0.2230
PaddleOCR	0.039	0.020(+48%)	0.2197

데이터 각각 10,000문장을 활용하였다.

학습모델은 Huggingface에 공개되어있는 wisenut-nlp-team/KoT5-base 모델을 활용하였으며, 검증 CER 성능이 수렴할 때까지 Early Stopping을 적용하여 학습하였다.

4.2 실험 결과

표 2에서 학습된 모델로 EasyOCR과 PaddleOCR을 수행한 문장들을 후보정한 결과, EasyOCR의 경우 0.074 오류율이 0.054로 약 27%개선되었으며, PaddleOCR은 0.039 오류율이 0.020으로 약 48%개선되었음을 알 수 있었다.

또한 동일한 평가 데이터를 ChatGPT API를 활용하여 교정을 요청하였을때 오류율이 오히려 상승하는 경향을 보였는데, 이는 틀린 부분만 교정을 수행하는 것이 아닌 맥락은 유지한채로 문장을 재생성하는 방식으로 교정이 수행되어 의미는 같지만 문장의 형태가 조금씩 달라지며 오류율이 상승하는 경향을 보였다. OCR 후보정의 경우 의미가 유지되는것도 중요하지만 글자가 온전히 복원되어야하는 경우가 많기때문에 상용 LLM을 활용하려면 프롬프팅 엔지니어링에 상당한 노력을 투자하거나 추가적인 튜닝이 필요함을 알 수 있다. 그림 2는 ChatGPT를 활용한 교정에 활용된 프롬프트이다.

System Prompt for OCR Correction with ChatGPT 4-o

"You are an expert in correcting grammar errors in texts extracted via Optical Character Recognition (OCR).
Your job is to correct each sentence into fluent and natural Korean without changing the original meaning.
Return only the corrected texts in the same order.
Do not explain anything."

그림 2. Chat GPT API를 활용한 OCR 후보정 프롬프트

5. 결론

본 연구는 OCR 후보정에 필요한 데이터를 보다 효율적으로 구축할 수 있는 방법을 제시하였다. CNN 기반의 글자 단위 오류 모방기를 활용하여 오류 가능성이 높은 글자 조합을 도출하고, 이를 실제 문장에 적용하여 OCR에서 흔히 나타나는 오류를 모방한 OCR 후보정 학습 데이터셋을 생성했다. 구축된 데이터셋은 실제 OCR 결과와 유사한 특성을 가지며, 후보정 모델의 성능 향상에도 기여할 수 있음을 실험을 통해 확인하였다. 제안된 방

식은 다양한 언어에서도 적용 가능하며, OCR 성능 개선을 위한 후보정 데이터 구축 비용을 크게 줄이고 OCR 품질을 향상시키는 실용적인 대안이 될 수 있다.

참고 문헌

- [1] S. Guan and D. Greene, "Advancing post-ocr correction: A comparative study of synthetic data," *arXiv preprint arXiv:2408.02253*, 2024.
- [2] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, "Gradient-based learning applied to document recognition," *Proceedings of the IEEE*, vol. 86, no. 11, pp. 2278–2324, 1998.
- [3] E. D'hondt, C. Grouin, and B. Grau, "Generating a training corpus for ocr post-correction using encoder-decoder model," in *Proceedings of the 8th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*, pp. 1006–1014, 2017.
- [4] E. Boros, N. K. Nguyen, G. Lejeune, and A. Doucet, "Assessing the impact of ocr noise on multilingual event detection over digitised documents," *International Journal on Digital Libraries*, vol. 23, no. 3, pp. 241–266, 2022.
- [5] R. Grundkiewicz, M. Junczys-Dowmunt, and K. Heafield, "Neural grammatical error correction systems with unsupervised pre-training on synthetic data," in *Proceedings of the Fourteenth Workshop on Innovative Use of NLP for Building Educational Applications*, pp. 252–263, 2019.
- [6] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 770–778, 2016.
- [7] N. I. S. Agency, "Korean-multilingual translation corpus (humanities)." <https://aihub.or.kr/aihubdata/data/view.do?currMenu=115&topMenu=100&aihubDataSe=data&dataSetSn=71498>, 2023. Dataset.
- [8] Y. Du, C. Li, R. Guo, X. Yin, W. Liu, J. Zhou, Y. Bai, Z. Yu, Y. Yang, Q. Dang, *et al.*, "Pp-ocr: A practical ultra lightweight ocr system," *arXiv preprint arXiv:2009.09941*, 2020.
- [9] C. Raffel, N. Shazeer, A. Roberts, K. Lee, S. Narang, M. Matena, Y. Zhou, W. Li, and P. J. Liu, "Exploring the limits of transfer learning with a unified text-to-text transformer," *Journal of machine learning research*, vol. 21, no. 140, pp. 1–67, 2020.