

LLM의 수능 수학 문제 풀이를 위한 시각 인지 자동화 파이프라인 구축 및 인간의 사고 과정 비교 분석

편고운[°], 허인범[°], 정지수, 황태욱, 정상근[†]
충남대학교 컴퓨터공학과

{vusrhdns714, inbum, jisju.jung5, taewook5295, hugmanskj}@gmail.com

Automated Visual Perception Pipeline for LLM-based CSAT Math Solutions: Comparing with Human Cognitive Processes

Goun Pyeon, Inbum Heo, Jeesu Jung, Taewook Hwang, Sangkeun Jung
Department of Computer Science & Engineering

요약

대형 언어모델(LLM)은 수학 문제 풀이에서 뛰어난 추론 능력을 보이며, 인공지능의 지능 수준을 평가하는 핵심 벤치마크로 활용되고 있다. 그러나 기존 벤치마크는 사람이 수행하는 시각적 인지 과정, 즉 시험지로부터 문항을 구분하고 시각 정보를 이해하는 절차에 의존하며, 이를 자동으로 대체할 수 있는 프로세스가 부재하다. 본 연구는 이러한 한계를 해결하기 위해, 문서 레이아웃 분석(Document Layout Analysis, DLA) 기반 시각정보 인지 단계를 통해 인간의 시각 인지 과정을 자동화하고, 그 결과를 LLM 추론 및 문제 풀이 단계로 전달하는 시각 인지 자동화 기반 수학 문제 풀이 파이프라인을 제안한다. 수능 수학 시험지를 대상으로 DLA 기반 입력과 수동 분할 입력을 비교한 실험에서, 두 방식은 전반적으로 유사한 점수를 보였으며 일부 영역에서는 DLA 기반 입력이 더 높은 점수를 보인다. 본 연구는 시각 인지 과정을 포함한 입력 방식이 LLM의 수학적 추론 평가에 미치는 영향을 분석하고, 인간 인지 기반 평가로의 확장 가능성을 제시한다.

1. 서론

대형 언어모델(LLM)은 수학 문제 풀이에서 우수한 추론 능력을 보이며, 인공지능의 지능 수준을 평가하는 핵심 벤치마크로 자리 잡고 있다. 대표적으로 MATH[1], GSM8K[2]와 같은 데이터셋이 LLM의 수학적 능력 평가에 널리 활용되고 있다. 그러나 이러한 벤치마크 평가 방식은 인간이 실제 수학 문제를 해결하는 과정과 근본적인 차이가 있다.

인간은 문제지를 보고 문항의 위치를 파악한 뒤 텍스트와 도형 등 시각적 정보를 종합적으로 이해하여 문제를 풀이한다. 반면 기존 수동 평가 파이프라인은 사람이 직접 문제를 분할하거나 텍스트를 입력해야 하므로, 실제 시험지에서의 시각적 인지 과정을 반영하지 못한다. 최근에는 문서 레이아웃 분석(DLA)과 비전-언어 모델(VLM)을 활용해 문항 영역을 자동 탐지 및 분할하는 연구가 활발히 이루어지고 있다[3, 4, 5]. 이러한 기술을 활용하여 인간의 문제 풀이 과정 중 ‘시각적 인지’를 자동화하여, 인간과 기계 간의 문제 풀이 과정의 괴리를 완화할 수 있다.

본 연구는 DLA 기반 시각정보 인지 단계와 LLM 문제 풀이 단계를 결합하여, 인간의 수학 문제 풀이 과정을 재현하는 시각 인지 자동화 기반 수학 문제 풀이 파이프라인을 구축하였다. 그림 1은 인간의 문제 풀이 과정, 기존의 수동 평가 파이프라인, 그리고 본 연구의 자동 파이프라인을 비교하여 시각 인지-추론-문제풀




그림 1: 인간의 문제 풀이 과정, 기존 수동 평가 파이프라인, 그리고 제안된 자동 평가 파이프라인 비교

이의 세 단계 대응 관계를 나타낸다. 구체적으로, 수능 수학 시험지(PDF)를 입력으로 받아 DLA 기반 시각정보 인지 단계에서 문항 영역을 자동 탐지 및 분할하고, 분할된 문항 이미지를 LLM 추론 및 문제 풀이 단계로 전달하여 정답을 산출하는 전 과정을 자동화했다. 또한, DLA 기반 입력과 수동 분할 입력이 LLM의 수학적 추론 성능에 미치는 영향을 정량적으로 분석했다.

본 연구의 주요 기여는 다음과 같다: (1) 인간의 문제 풀이 과정을 반영한 비정형 문서 기반 LLM 평가 파이프라인 구축 (2)

[°] 공동 1저자 (Equal contribution).

[†] 교신저자 (Corresponding author).

* 이 논문은 2025년도 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 연구임 (No.RS-2022-00155857, 인공지능융합혁신인재양성(충남대학교)).

DLA 기반 분할과 수작업 문항 분할 간의 LLM 추론 성능 비교를 통한 문서 파싱 과정의 영향 분석 (3) 다양한 LLM을 대상으로 한 수학문제의 단원별·유형별·난이도별 추론 성능 분석

2. 관련 연구

문서 레이아웃 분석(DLA)은 문서 이미지에서 텍스트, 표, 그림 등 구성 요소를 자동 탐지·분류하는 기술로, 최근 객체 탐지 기반 모델[6, 5]과 비전-언어 모델(VLM)[7]의 발전과 함께 주목받고 있다. 대표 데이터셋으로는 PubMed 논문 기반의 PubLayNet[8]과 다양한 도메인을 포함한 인간 주석 기반의 DocLayNet[4]이 있다. 모델 측면에서 DocLayout-YOLO[6]는 실시간성과 정확도를, LayoutLMv3[5]는 멀티모달 문서 이해 능력을 보인다. 최근 DeepSeek-OCR[7] 등 VLM은 텍스트 인식과 문서 이해를 통합 수행하며 복합 문서 처리에 강점을 보이고 있다.

LLM의 수학 추론 능력 평가는 대표적으로 MATH[1]와 GSM8K[2]와 같은 벤치마크로 이루어지며, MathVerse[3]는 시각 정보를 포함한 수학 문제에 대한 멀티모달 평가를 시도하였다. 그러나 대부분 단일 문제 단위의 전처리된 입력에 한정되어 있어, 실제 시험지처럼 복잡한 레이아웃 환경에서의 문제 풀이 성능 평가는 부족하다. 본 연구는 DLA 기반 자동 파싱을 활용해 LLM의 수학 풀이 성능에 미치는 영향을 정량 분석하고, 현실적 자동 문제 풀이 시스템의 가능성을 탐색한다.

3. 시각 인지 자동화 기반 LLM 수학 문제 풀이

본 연구는 DLA 기반 시각정보 인지 단계와 LLM 추론 및 문제 풀이 단계를 결합하여, 수능 수학 시험지로부터 문항 단위 입력을 자동 생성하고 문제를 해결하는 시각 인지 기반 수학 문제 풀이 파이프라인을 제안한다. 제안된 파이프라인은 인간의 시각 인지 과정을 자동화하여 실제 시험지 형태의 입력을 처리하도록 설계되었으며, DLA 기반 시각정보 인지 단계와 LLM 추론 및 문제 풀이 단계의 두 단계로 구성된다.

DLA 기반 시각정보 인지 시험지 PDF를 페이지 단위로 이미지화한 뒤, 해상도 정규화와 노이즈 제거를 수행하고 DeepSeek-OCR [7]을 이용하여 텍스트·수식·도형 영역을 인지하였다. 모델은 추가 학습 없이 공개된 가중치를 사용하였으며, 좌표와 텍스트 정보를 기반으로 문항 단위 이미지를 자동으로 추출하였다. 비교 실험을 위해 사람이 수동으로 분할한 수동 분할 입력을 기반으로 한 데이터를 구성하였고, 각 문항을 스크린샷한 이미지를 LLM 추론 및 문제 풀이 단계의 입력으로 사용하였다.

LLM 추론 및 문제풀이 DLA 기반 입력 또는 수동 분할 입력으로부터 얻은 각 문항 이미지는 한 문항씩 독립적으로 LLM에 입력된다. 문항 별 이미지는 base64 형식으로 인코딩되어 LLM에 전달되며, 모든 모델은 동일한 프롬프트를 사용하였다. 따라서 LLM 입력은 문항 별 이미지 + 풀이를 위한 프롬프트만으로 구성되며, 다른 OCR된 텍스트 정보 등은 포함되지 않는다. LLM

은 멀티모달 입력을 지원하는 설정에서 평가되었으며, 각 문항은 독립적으로 추론되어 문제 간 문맥 정보는 공유되지 않는다.

4. 실험 및 결과 분석

4.1 실험 설계

본 연구에서는 제안된 파이프라인의 유효성을 검증하기 위해 2023-2025학년도(3개년) 대학수학능력시험(이하 수능) 수학 영역을 대상으로 실험을 수행하였다. 수능의 경우 홀수형, 짝수형으로 구분되나 문제 내용은 동일하므로 실험에는 홀수형만을 사용하였으며, 모든 시험지는 PDF 형식으로부터 수동 및 DLA 기반 자동 문항 분할 데이터를 구축하였다.

실험에는 다음의 모델을 활용하였다:

- **DLA 모델:** 문서 내 수식, 도형, 텍스트 영역을 인지하기 위해 DeepSeek-OCR[7] 모델을 사용하였다.
- **LLM:** 여섯 개의 대표 모델을 대상으로 실험을 수행하였다.
 - 상용 모델: GPT 5[9], GPT 4o mini[10], Gemini 2.5 Pro, Gemini 2.5 Flash[11]
 - 오픈 모델: Qwen3 VL 235B, Qwen3 VL 8B[12]

각 모델은 동일한 문항을 대상으로 **DLA 기반 입력**과 **수동 분할 입력** 두 조건에서 문제를 풀이하였다. LLM의 최종 출력으로부터 정답을 정규표현식을 이용해 추출한 뒤, 정답 일치 여부를 기준으로 정답률을 산출하고, 추가적으로 모델별·단원별·난이도별 점수를 분석하였다.

4.2 실험 결과 및 분석

표 1은 각 LLM의 수능형 조합별 맞춘 개수 및 총점을 요약한 것으로, 문항 수는 공통수학(수학I 11문제, 수학II 11문제)은 총 22문제, 확률과통계(확통)·미적분·기하는 각 8문제로 이루어져 있다. 점수는 공통수학(수학I 37점, 수학II 37점)이 74점, 확률과통계가 26점, 미적분이 26점, 그리고 기하가 26점으로, 총점은 152점으로 구성된다.

표 1: LLM 모델별 수능형 수학 모의 평가 점수. 2023-2025 년도의 결과를 모두 표기하기 위해 각 셀별로 23/24/25년도 점수를 복합 표기하였다.

모델	입력	공통(74)	확통(26)	미적분(26)	기하(26)	총점(152)
GPT 5	수동	72/74/74	26/19/26	26/26/22	26/26/26	150/145/148
	DLA	66/66/63	26/26/22	26/26/22	26/26/26	144/144/133
GPT 4o mini	수동	37/30/28	11/12/14	5/5/5	5/11/2	58/58/49
	DLA	23/27/33	11/8/14	9/8/11	5/12/5	48/55/63
Gemini 2.5 Pro	수동	72/74/74	26/10/26	26/23/26	22/26/22	146/142/148
	DLA	62/62/63	26/26/26	22/26/22	22/26/26	132/140/137
Gemini 2.5 Flash	수동	60/58/62	15/19/18	18/15/18	22/12/23	115/104/121
	DLA	52/58/55	23/26/18	26/19/26	26/15/19	127/118/118
Qwen3 VL 235B	수동	64/65/62	22/19/26	18/11/15	26/18/22	130/114/125
	DLA	55/46/48	22/26/26	18/22/23	26/18/23	121/112/120
Qwen3 VL 8B	수동	53/54/43	18/11/13	17/8/13	19/9/26	107/82/95
	DLA	31/38/38	10/16/26	15/9/12	23/13/19	78/76/95

시각 인지 기반(DLA) vs 수동 분할 비교 대부분의 모델에서 수동 분할 입력이 DLA 기반 입력보다 약간 더 높은 점수를 보였다. 수동 분할 입력 대비 DLA 기반 입력의 평균 점수 차이는 약 10 점으로, 수능 수학의 배점 구조(2·3·4점)를 고려하면 대략 2-3 문항의 오차에 해당한다. DLA 기반 입력의 점수는 전반적으로 수동 분할과 유사했으나, 일부 문항에서는 그림이나 수식 일부가 잘리거나 불필요한 여백이 포함되었다. 이러한 시각적 왜곡이 모델의 문제 인지에 영향을 끼친 것으로 보인다.

모델 크기별 경향 모델 크기에 따라 입력 방식에 따른 총점 차이가 달랐다. 대형 모델일수록 입력 방식의 영향이 작았으며, 대부분의 경우 수동 분할 입력에서 DLA 기반 입력보다 높은 점수를 보였다. 예를 들어, Qwen3-VL-235B는 8B 모델에 비해 두 입력 간 점수 차이가 현저히 작았으며, 이는 **대규모 모델이 시각적 결함을 보정하거나 문항 구조를 추론적으로 복원하는 능력을 갖추었음을 시사한다.** 이 외에도 대형 모델(GPT 5, Gemini 2.5 Pro, Qwen3 VL 235B)은 소형 모델보다 높은 총점을 보였으며, 소형 모델은 입력 방식에 더 민감해 일부 경우(GPT-4o-mini-2025, Gemini-2.5-Flash-2023·2024)에서는 오히려 DLA 기반 입력이 수동 분할 입력보다 높았다.

문제 영역별 경향 문제 영역별 점수 경향은 다소 상이하게 나타났다. 공통수학 영역에서는 대부분의 모델에서 수동 분할 입력이 DLA 기반 입력보다 높은 점수를 보였다. 그러나 일부 소형 모델에서는 DLA 기반 입력 시 오히려 더 높은 점수가 관찰되었다. 영역별 만점 횟수는 수동 분할 기반 결과가 공통 4회, 확률과 통계 5회, 미적분 4회, 기하 5회였으며, DLA 기반 결과는 각각 0회, 9회, 5회, 7회로 나타났다. 공통수학을 제외한 선택과목 영역에서는 DLA 기반 입력의 만점 빈도가 더 높았다.

종합하면, 수동 분할 입력이 전반적으로 우세하지만, DLA 기반 입력도 일부 조건에서 수동 입력과 유사하거나 더 높은 점수를 보였다. 특히 대형 모델에서는 두 입력 방식 간 점수 차이가 작았으며, 이는 DLA 기반 접근이 실제 평가 파이프라인에서도 신뢰 가능한 입력 생성 방식임을 보인다.

5. 결론

본 연구는 DLA 기반 시각정보 인식 단계와 LLM 추론 및 문제 풀이 단계를 결합하여, 시험지 형태의 수학 문제를 자동 인식, 풀이하는 시각 인지 기반 수학 문제 풀이 파이프라인을 구축하고, 이를 수동 분할 기반 입력 파이프라인과 비교하여 LLM 성능을 평가하였다. 실험 결과, DLA 기반 입력은 수동 입력 대비 일부 점수 하락이 관찰되었으나, 대형 모델에서는 입력 방식에 따른 차이가 작았고, 소형 모델에서는 경우에 따라 DLA 기반 입력이 더 높은 성능을 보였다. 이는 DLA 기반 접근이 실제 시험지 수준의 시각 정보를 효과적으로 처리할 수 있음을 보여주며, 향후 시각 정보 보정 및 고난도 문항 특화 후처리 연구를 통해 완전 자동 문제 풀이의 실용적 확장 가능성을 시사한다.

참고 문헌

- [1] D. Hendrycks, C. Burns, S. Kadavath, A. Arora, S. Basart, E. Tang, D. Song, and J. Steinhardt, "Measuring mathematical problem solving with the MATH dataset," in *Thirty-fifth Conference on Neural Information Processing Systems Datasets and Benchmarks Track (Round 2)*, 2021.
- [2] K. Cobbe, V. Kosaraju, M. Bavarian, M. Chen, H. Jun, L. Kaiser, M. Plappert, J. Tworek, J. Hilton, R. Nakano, C. Hesse, and J. Schulman, "Training verifiers to solve math word problems," 2021.
- [3] R. Zhang, D. Jiang, Y. Zhang, H. Lin, Z. Guo, P. Qiu, A. Zhou, P. Lu, K.-W. Chang, P. Gao, and H. Li, "Mathverse: Does your multi-modal llm truly see the diagrams in visual math problems?," 2024.
- [4] B. Pfizmann, C. Auer, M. Dolfi, A. S. Nassar, and P. Staar, "Doclaynet: A large human-annotated dataset for document-layout segmentation," in *Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, KDD '22, p. 3743–3751, ACM, Aug. 2022.
- [5] Y. Huang, T. Lv, L. Cui, Y. Lu, and F. Wei, "Layoutlmv3: Pre-training for document ai with unified text and image masking," 2022.
- [6] Z. Zhao, H. Kang, B. Wang, and C. He, "Doclayout-yolo: Enhancing document layout analysis through diverse synthetic data and global-to-local adaptive perception," 2024.
- [7] H. Wei, Y. Sun, and Y. Li, "Deepseek-ocr: Contexts optical compression," 2025.
- [8] X. Zhong, J. Tang, and A. J. Yepes, "Publaynet: largest dataset ever for document layout analysis," 2019.
- [9] "Gpt-5 is here — openai." <https://openai.com/gpt-5/>, 2025.
- [10] "Gpt-4o mini: advancing cost-efficient intelligence — openai," 2025.
- [11] G. Comanici, E. Bieber, M. Schaekermann, I. Pasupat, N. Sachdeva, I. Dhillon, M. Blistein, O. Ram, D. Zhang, E. Rosen, *et al.*, "Gemini 2.5: Pushing the frontier with advanced reasoning, multimodality, long context, and next generation agentic capabilities," *arXiv preprint arXiv:2507.06261*, 2025.
- [12] "Qwen3-vl: Sharper vision, deeper thought, broader action," 2025.