

Mixing Augmentation과 UNet을 활용한 상표 이미지 군집화 및 거리기반 유사성 측정

황태욱*, 허인범**, 정다혜***, 정상근*

충남대학교 컴퓨터융합학부*, 천문우주과학과**, 전파정보통신공학과***

taewook5295@gmail.com, inbum10222@gmail.com, dsSupnbb79@gmail.com, hugman@cnu.ac.kr

Trademark Image Clustering and Distance based Similarity Estimation with Mixing Augmentation and UNet

Taewook Hwang*, Inbeom Heo**, Dahye Jung***, Sangkeun Jung*

Division of Computer Convergence*, Department of Astronomy and Space Science**,

Department of Radio and Information Communications Engineering***, Chungnam National University

요 약

본 연구는 상표 이미지 표절 자동 심사를 위한 데이터가 부족한 상황에서, 생성기법을 활용한 딥러닝 기반의 클러스터링 모델 학습 및 거리기반 유사성 판단 방법을 제안한다. 상표 이미지는 단일 데이터이므로, 학습 및 평가를 위해서 mixing augmentation을 통한 데이터 증강을 수행한다. UNet 모델로 원본이미지 복원 학습을 통해 이미지의 특징을 추출하고, 잠재 벡터공간 상에서 triplet margin loss를 활용하여 입력된 기준 이미지와 긍정 이미지의 위치는 가깝게, 기준 이미지와 부정 이미지는 멀리 배치되게 학습하여 상표 이미지마다 하나의 군집을 형성하게 학습한다. 군집화된 벡터 공간을 활용하여 학습에 사용한 상표 이미지들과 mixing augmentation을 통해 임의로 생성한 표절 이미지로 정확성을 측정하였을 때, 약 86%의 성능을 달성하였다.

1. 서 론

최근 DALL-E와 ChatGPT 등 초거대 딥러닝 모델들이 등장하면서 다양한 분야를 통틀어 인간을 뛰어넘는 능력을 보이고 있다. 딥러닝 기술이 발전함에 따라 다양한 분야에 적용되고 있으나 이러한 고성능 딥러닝 모델을 위해서는 많은 시간과 GPU 자원, 그리고 질 좋은 대규모 데이터셋이 필요하다.

이러한 대규모 데이터를 확보하려면 상당한 비용이 필요하며, 쉽게 접근할 수 있는 데이터가 있어도 그 질이 반드시 좋은 것은 아니다. 데이터의 낮은 품질이나 불균형은 모델의 성능 저하를 유발하므로 높은 성능의 AI를 구축하려면 대규모이면서도 고품질의 데이터가 필수적이다.

양질의 데이터셋 확보가 어려운 분야 중 하나로 상표 유사성 판단 분야가 있다. 상표는 각 기업의 제품을 쉽게 식별할 수 있게 해주며, 소비자에게 기업의 전문성과 신뢰성을 부각하여 상품 구매에 상당한 영향을 준다[1]. 즉, 잘 구축된 상표는 상당한 영향력을 행사하므로, 이를 표절하거나 무단으로 사용하는 등 저작권 침해 문제가 빈번히 발생하여 피해가 꾸준히 발생하고 있다. 또한, 심사관의 주관에 따라 심사 결과가 달라질 수 있고, 수동 심사과정에서 방대한 양의 상표를 모두 확인해야하므로 실수가 발생하는 경우가 종종 있다[2].

이에 본 논문에서는 상표 유사성 판단 기술을 위한 데이터셋 확보와 생성기법을 활용한 군집화를 제안한다. 데이터의 결핍을 해결하고자 데이터 증강, few-shot learning 등 다양한 연구가 수행되고 있다. 본 연구에서는 데이터 증강 중 이미지 mixing augmentation[3]과 생성기반 학습을 수행하여 단일 데이터(unique data)인 상표 이미지를 학습하면서 벡터를 군집화하여 거리기반의 유사성을 측정하는 방법을 제안한다.

2. 관련 연구

[2]는 CNN 모델을 활용하여 상표 이미지 특징을 추출한 뒤 주성분분석(principal component analysis)을 수행하여 벡터를 획득한다. 신규 상표의 벡터와 기존 등록 상표들의 유클리디안 거리를 계산하고 이를 유사도로 활용하였다.

[4]는 이미지 딥러닝 모델을 활용하여 온라인 제품 이미지로부터 상표 이미지를 인식 및 잘라낸다. ResNet[5]를 활용하여 이렇게 모아진 데이터와 triplet margin loss를 통해 거리기반 학습을 수행하였다.

고성능의 딥러닝 학습을 위해서는 과적합을 방지할 수 있는 대규모 데이터가 필수적이다. 이러한 이미지 데이터셋을 구축하기 위해 다양한 증강 기법이 사용되고 있다. [3]은 이러한 mixing augmentation을 조사한 논문으로, 우리는 이 중 mixup[6]과 cutmix[7] 기법을 사용한다. Mixup은 두 개의 이미지의 픽셀값을 가중 평균내어 사용하는 하나의 이미지처럼 생성하는 방식으로, 두 개의 이미지가 가중치에 따라 반투명하게 겹쳐진다. Cutmix는 이미지 일부를 잘라내어 다른 이미지에 붙이는 방식이다.

클러스터링은 대표적인 비지도학습 방식으로 다양한 표현 학습을 통해 데이터를 잘 임베딩하여 벡터공간에 군집을 구성한다. 데이터가 점점 복잡해지고 다양한 표현 학습 기법이 등장함에 따라 클러스터링을 통해 데이터에 라벨을 부착하고 이를 다시 학습에 활용하는 등, 딥러닝을 활용한 클러스터링 학습 방법이 활발히 연구되고 있다[8,9].

[10]은 다양한 증강 기법을 활용해 적은 데이터로도 우수한 세그멘테이션을 수행하기 위한 모델이다. 입력 이미지로부터 매 단계마다 특징을 추출하여 압축한 뒤 이를 다시 원본 이미지 크기로 복원하는 모델로, 생성 모델로 사용이 가능하다.




그림 1. 상표 이미지 유사도 판단 모델 구조도

3. 상표 이미지 군집화 및 거리기반 유사성 측정 모델

우리는 상표 이미지의 클러스터링을 통해 신규 상표와 기존 상표들의 거리기반 유사성을 판단할 수 있는 기술을 제안한다. 상표 이미지는 단일 데이터이므로 학습 및 평가를 위해 데이터 증강이 필요하다. 이 때 증강된 데이터는 표절 이미지처럼 기존 이미지와 상당히 유사해야한다. 따라서 우리는 회전, 반전, 리사이즈 등, 주로 사용되는 증강대신 이미지의 원형을 최대한 포함할 수 있는 mixing augmentation을 활용한다.

또한 이미지의 특징을 추출하기 위해 UNet과 ResNet을 활용하여 원본 이미지 복원을 통해 모델 학습을 수행한다. 동시에 UNet 가장 밑단의 레이어가 생성하는 잠재벡터(latent vector)로 triplet margin loss를 계산하여 벡터공간에서 상표 이미지 하나당 하나의 군집이 형성되도록 학습을 수행한다.

그림 1은 제안 방법을 도식화한 것으로 좌측의 Anchor Dataset은 기존 등록된 상표 이미지로 triplet margin loss 계산 시 기준이 되는 이미지이다. Noise Dataset은 기존 상표 이미지와 mixing augmentation을 수행하여 triplet margin loss 계산 시 표절로 취급하는 긍정 이미지를 생성하거나, 기존 이미지와 다른 상표인 부정 이미지를 선택할 때 사

용한다.

모델은 입력된 기준, 긍정, 부정 이미지 복원을 통해 계산되는 3개의 Mean Squared Error loss 값과 triplet margin loss 값을 더한 값을 최종 train loss 값으로 사용한다. 이미지 복원 학습을 통해 이미지의 특징을 잘 추출해낼 수 있고, 기준 이미지와 긍정 이미지는 가까운 위치에, 기준 이미지와 부정 이미지는 먼 위치에 배치되도록 학습하면서 벡터공간 상에 상표 이미지마다 하나의 군집을 형성한다.

4. 실험

본 실험을 통해 상표 이미지와 표절 이미지가 벡터공간 상에서 가까운 위치에 있는지와 서로 다른 상표 이미지들은 충분히 먼 위치에 있는지를 확인하고자 한다. 또한, 이렇게 구성된 벡터공간과 기준값(threshold)를 활용하여 mixing augmentation을 통해 생성된 표절 이미지가 입력되었을 때 표절임을 확인할 수 있는지와 신규 상표가 입력되었을 때 신규임을 확인할 수 있는지 검증하고자 한다.

실험에 사용된 데이터셋은 AIHub의 유사 상표 이미지 검색 서비스의 사용자 입력 이미지 데이터¹⁾로, 등록된 상표 이미지

표 1. 각 실험별 유클리디안 거리와 정확도

Backbone	Noise	Euclidean Distance						Accuracy		
		Anchor-Positive			Anchor-Negative					
		baseline	mixup	cutmix	baseline	mixup	cutmix	baseline	mixup	cutmix
resnet-34	0.1		82.21	71.54		149.63	149.53		0.854	0.852
	0.3		111.25	103.52		144.73	166.06		0.660	0.787
	0.5	98.28	113.87	118.28	128.64	127.28	162.92	0.343	0.314	0.600
	0.7		119.88	118.28		124.49	147.80		0.133	0.506
resnet-50	0.1		87.10	73.28		147.71	143.62		0.845	0.865
	0.3		120.72	101.08		149.33	153.82		0.596	0.806
	0.5	98.44	129.60	114.22	125.29	138.95	149.26	0.190	0.263	0.541
	0.7		124.76	119.22		127.97	139.35		0.202	0.289

1) <https://www.aihub.or.kr/aihubdata/data/view.do?currMenu=&topMenu=&aihubDataSe=realm&dataSetSn=71285>




그림 2. 기준-긍정 이미지와 기준-부정 이미지의 거리

와 해당 상표의 도형코드(vienna code) 등의 정보가 담겨있다. 우리는 해당 데이터 중 도형코드가 2603인, 삼각형 혹은 각을 형성하는 상표 이미지만을 선별하여 사용하였다. 실험에 사용된 이미지는 모두 흑백으로 변환하여 사용하였다.

학습 데이터는 5,126개, 검증 및 평가 데이터는 각각 724개이다. 그림 1의 Anchor Dataset은 항상 학습 데이터로 사용되고, Noise Dataset은 학습 시에는 학습 데이터로, 검증 시에는 검증 데이터, 평가 시에는 평가 데이터로 사용한다.

사용된 모델은 ResNet34와 ResNet50을 백본으로 사용하는 UNet이다. 배치 사이즈는 32로 고정하였고, 검증 과정에서 triplet margin loss 값을 기준으로 patience가 5인 조기 종료(early stopping)를 사용하여 학습하였다. 옵티마이저로 학습률(learning rate)이 $1e^{-5}$ 인 AdamW를 사용하였다.

실험은 2개의 ResNet 모델과 5개의 증강 정책을 적용하여 총 10번을 수행하였다. SVHNPoly[11]를 따라 증강을 수행한 것을 baseline으로 사용하고, mixing augmentation과정에서 노이즈 이미지의 반영 비율을 0.1, 0.3, 0.5, 0.7 개로 두어 모델마다 4번의 실험을 수행하였다.

표 1은 실험 결과로, 벡터공간상에서 기준과 긍정 이미지의 거리와 기준과 부정 이미지의 거리를 측정하였고, 기준값을 설정하여 기준과 긍정, 부정 이미지 유사성 판단 결과를 정확도로 측정하였다.

노이즈가 작을수록 대체로 좋은 성능을 보였고, cutmix가 mixup에 비해 조금 더 좋은 성능을 보였다. 노이즈가 0.5인 것은 기준 이미지와 노이즈 이미지를 반반씩 섞은 것으로, 상당히 다른 데이터라고 볼 수 있다. 그래서 노이즈가 0.3보다 커지면 성능이 급격히 떨어진다. 이는 그림 2를 통해서도 확인할 수 있다. 기준-긍정 이미지의 거리는 작아야하고 기준-부정 이미지의 거리는 커야하며, 둘의 차이가 클수록 이상적인 클러스터링이 된 것으로 볼 수 있다.

5. 결 론

우리는 생성기법을 활용한 딥러닝 기반의 클러스터링 모델 학습 및 거리기반 유사성 판단 방법을 제안하였다. 상표 이미지는 단일 데이터로, 학습 및 평가를 위해서 mixing augmentation을 통한 데이터 증강을 수행하였다. ResNet을 백본으로 사용하는 UNet 모델로 원본이미지 복원 학습을 통해 이미지의 특징을 추출하였고, 벡터공간 상에서 입력된 기준 이미지와 긍정 이미지의 위치는 가깝게, 기준 이미지와 부정 이미지는 멀리 배치되게 학습하여 상표 이미지마다 하나의 군집을 형성하게 학습하였다.

일반적으로 사용되는 SVHNPoly로 증강한 baseline과 mixup과 cutmix 기법으로 증강한 실험을 비교한 결과, 두 방식 모두 baseline보다 높은 성능을 보였다. 상표 이미지의 경우 널리 사용되는 증강 방식보다 mixing augmentation이 더욱 효과적임을 확인하였으며, 이를 통해 상표의 표절 여부를 판단할 수 있음을 확인하였다.

향후 연구로는 여러 종류의 비엔나 코드에 해당하는 데이터셋으로 추가 실험을 진행할 예정이고, 실제 상표 등록이 취하되거나 표절로 인해 거절된 상표이미지 등을 수집하여 실험을 수행하고자 한다.

참 고 문 헌

- [1] Macias, Washington, and J. Cerviño. "Trademark dilution and its practical effect on purchase decision." *Spanish Journal of Marketing-ESIC* 21.1 (2017): 1-13.
- [2] Alshowaish, Hayfa, Yousef Al-Ohali, and Abeer Al-Nafjan. "Trademark image similarity detection using convolutional neural network." *Applied Sciences* 12.3 (2022): 1752.
- [3] Cao, Chengtai, et al. "A survey of mix-based data augmentation: Taxonomy, methods, applications, and explainability." *arXiv preprint arXiv:2212.10888* (2022).
- [4] Trappey, Amy JC, Charles V. Trappey, and Eason Lin. "Intelligent trademark recognition and similarity analysis using a two-stage transfer learning approach." *Advanced Engineering Informatics* 52 (2022): 101567.
- [5] He, Kaiming, et al. "Deep residual learning for image recognition." *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2016.
- [6] Zhang, Hongyi, et al. "mixup: Beyond empirical risk minimization." *arXiv preprint arXiv:1710.09412* (2017).
- [7] Yun, Sangdoo, et al. "Cutmix: Regularization strategy to train strong classifiers with localizable features." *Proceedings of the IEEE/CVF international conference on computer vision*. 2019.
- [8] Zhou, Sheng, et al. "A comprehensive survey on deep clustering: Taxonomy, challenges, and future directions." *arXiv preprint arXiv:2206.07579* (2022).
- [9] Caron, Mathilde, et al. "Deep clustering for unsupervised learning of visual features." *Proceedings of the European conference on computer vision (ECCV)*. 2018.
- [10] Ronneberger, Olaf, Philipp Fischer, and Thomas Brox. "U-net: Convolutional networks for biomedical image segmentation." *Medical Image Computing and Computer-Assisted Intervention - MICCAI 2015: 18th International Conference, Munich, Germany, October 5-9, 2015, Proceedings, Part III* 18. Springer International Publishing, 2015.
- [11] Cubuk, Ekin D., et al. "Autoaugment: Learning augmentation policies from data." *arXiv preprint arXiv:1805.09501* (2018).