

수식 검출 태스크에 대한 기존 OCR 모델의 한계점 분석

황태욱¹, 허인범², 정상근¹

충남대학교 컴퓨터공학과¹, 충남대학교 천문우주과학과²

{taewook5295, inbum10222}@gmail.com, hugman@cnu.ac.kr

Analysis of Limitations of OCR Models for Mathematical Expression Detection Task

Taewook Hwang¹, Inbum Heo², Sangkeun Jung¹

Computer Science & Engineering, Chungnam National University¹

Department of Astronomy and Space Science, Chungnam National University²

요약

본 연구는 향후 교육용 AI 기술을 위해 수식 검출의 중요성을 강조하고자 합성 데이터셋을 구축하고 다양한 OCR 모델들의 성능을 평가하고 한계점을 확인하였다. 수식 검출 데이터셋은 17개의 나눔 폰트와 Faker 라이브러리를 활용하여 한글 및 영어의 랜덤 텍스트를 생성하고, ChatGPT를 활용하여 총 120개의 다양한 수식을 생성하여 구성되었다. 생성된 데이터셋은 수식만 포함된 데이터, 텍스트만 포함된 데이터, 그리고 수식과 텍스트가 혼합된 데이터를 포함하며, 각각 한글과 영어로 240개씩 생성되었다. 실험 결과, 대부분의 모델에서 영어에 비해 한국어 인식 성능이 낮았으며, 특히 수식과 텍스트가 혼합된 경우 성능 저하가 더 두드러졌다. EasyOCR과 PORORO와 같은 한국어에 특화된 모델은 영어와 한국어 간 성능 차이가 적었으나, 수식과 텍스트가 혼합된 경우 성능이 저하되는 문제는 여전히 존재하였다. 이를 통해, 향후 수식 인식과 한국어 인식 성능을 개선하기 위한 데이터셋 구축과 이를 활용한 태스크의 중요성을 강조하고자 한다.

1. 서론

최근 인공지능 기술의 급격한 발전으로 교육용 AI에 대한 관심이 급증하고 있다. 교육 자료를 디지털화하고 이를 AI 모델이 효과적으로 이해하기 위해서는 문자인식(OCR)과 문서 레이아웃 분석(DLA) 기술의 정밀도 향상과 복잡한 레이아웃 처리 능력의 개선이 필수적이다. 특히, 이러한 기술들이 교육 자료에 내재화되기 위해서는 텍스트와 시각적 정보를 동시에 처리할 수 있는 능력이 요구되며, 이 과정에서 수식과 같은 복잡한 구성 요소는 주요한 도전 과제 중 하나이다. 그림 1과 같이 수식 검출의 중요성은 간과되어 있으며, 수식 검출이 제대로 이루어지지 않을 경우 교육용 AI는 학습 자료의 수식을 정확히 이해하지 못하여 수학적 개념 학습에서 큰 제약이 발생할 수 있다.




그림 1. 기존 OCR 과정, 수식 검출은 간과되는 경우가 많음

그러나 한국어와 수식 인식과 관련된 데이터셋이나 기술적 연구는 미비한 실정이다. 한국어는 독창적인 문자 형태와 복잡한 어순 및 문법적 특성으로 인해 OCR 기술 적용에 어려움이 있다.




그림 2. 수식 검출 데이터셋, 수식, 글, 폰트를 랜덤하게 선택함

수식 또한 다양한 기호와 복잡한 구조적 특성으로 인해 기존의 OCR 및 DLA 기술로는 효과적으로 인식하기 어려운 요소이다. 현재 대부분의 수식 인식은 수작업으로 수식 영역을 추출하고 이를 OCR 모델에 입력하는 방식이며, 이는 비용이 많이 들고 대규모 데이터 처리에 한계가 있는 비효율적인 방식이다[1].

특히 수식과 텍스트가 혼용된 경우, 기존의 OCR 모델들은 수식과 텍스트 영역을 정확하게 구분하지 못해 인식 성능이 저하되는 문제가 빈번히 발생한다. 이러한 한계를 극복하기 위해 본 연구에서는 수식 영역 검출의 중요성을 강조하며, 그림 2와 같이, 이를 위한 합성 데이터셋을 제안한다. 제안된 합성 데이터셋은 다양한 수식과 텍스트의 조합을 포함하고 있으며, 수식과 일반 텍스트를 동시에 높은 정확도로 인식할 수 있도록 지원하는 것을 목표로 한다.

실험 결과, 기존 OCR 모델들은 한국어와 수식이 포함된 합성 데이터셋에서 영어에 비해 낮은 인식 성능을 보임을 확인하였다.

2. 관련 연구

CRFAT(Character Region Awareness For Text detection)는 문자 단위로 텍스트 영역을 탐지하는 OCR 모델로 다른 모델에

이 논문은 충남대학교 학술연구비, 한국연구재단의 기초연구사업(2022R1F1A1071047), 정보통신기획평가원의 인공지능융합혁신인재양성사업(충남대학교)(No.RS-2022-00155857)의 지원을 받아 수행된 연구임

비해 한글에 적합하며[2], EasyOCR¹에서 문자 검출엔진으로 활용되고 있다. Tesseract[3]는 전통적인 방식의 OCR엔진이며, PaddleOCR[4]은 딥러닝 기반의 OCR엔진으로, 다양한 언어를 지원한다. 또한 [5]은 그림, 도표, 수식 등을 인식하기 위해 어텐션 매커니즘을 활용하여 글자를 단계적으로 인식하는 방법을 제안하였다.

CHROME 2014 데이터셋[6]은 수식 필기 인식을 위한 대회에서 사용된 데이터셋으로, 필기 수식 인식을 위해 주로 사용된다. im2latex-100k 데이터셋[5]은 인쇄된 수식 이미지와 해당 LaTeX 표현식으로 구성된 합성 데이터셋으로, 수식 인식 모델의 학습에 활용된다.

3. 수식 검출 데이터셋

본 연구에서는 수식 검출 데이터셋을 구축하기 위해 다양한 접근 방식을 활용하였다. 우선, 17개의 나눔 폰트²를 사용하여 한글 텍스트를 생성하였으며, 이로써 다양한 서체에서의 수식 인식 성능을 평가할 수 있는 기반을 마련하였다. 또한, Faker 라이브러리를 활용하여 한글과 영어의 랜덤 텍스트를 생성함으로써 실제 교육 자료와 유사한 텍스트 데이터를 확보하였다.

수식의 경우, ChatGPT를 활용하여 다양한 유형의 수식을 생성하였다. 구체적으로 사용된 공식은 표 1과 같다.

표 1. 데이터셋 생성에 사용된 수식

Category	Count
Famous Expressions	10
Polynomial Expressions	10
Differential Expressions	30
Integral Expressions	30
Complex and Other Expressions	20
Calculus Series	20
Total Expressions	120

테스트를 위해 수식만 포함된 데이터, 텍스트만 포함된 데이터, 그리고 수식과 텍스트가 혼합된 데이터를 각각 한글과 영어로 240개씩 생성하였다. 생성된 데이터는 수식과 텍스트가 혼재된 상황에서의 모델 성능을 평가하는 데 중요한 역할을 하며, 특히 다양한 폰트를 적용함으로써 현실 문제에 강건할 수 있도록 유도하였다.

생성된 이미지의 크기는 가로 형태의 A4용지 비율에서 높이를 절반으로 줄인 약 8:3의 비율로 설정하였으며, 해당 이미지 안에 텍스트와 수식이 랜덤하게 배치되도록 하였다. 이로써 다양한 레이아웃에서의 수식 인식 성능을 평가할 수 있도록 하였으며, 교육 자료 내의 수식 검출 및 인식에 대한 보다 정교한 모델 평가가 가능할 것으로 기대한다.

4. 실험

4.1 실험 설계

본 실험에서는 Tesseract[3], PaddleOCR[4], EasyOCR, KerasOCR³, PORORO⁴ 총 5개의 OCR 모델들을 사용하여 성능을 평가하였다. 모델의 성능을 측정하기 위한 평가지표로는 BLEU, PopEval[7], ROUGE-2를 사용하였다. BLEU는 n-gram을 1부터 4까지 설정하여 평가한 점수를 조화평균을 사용하여 측정하였고, PopEval은 공백 등의 문제로 텍스트 영역이 분할 및 병합되어 생긴 오류를 보정하여 성능을 평가하는 지표이다.

모델의 평가는 본 연구에서 구축한 수식 검출 데이터셋을 활용하여 정답 문장과 OCR모델이 인식한 텍스트 및 수식으로 이루어진 문장을 비교하였다. 문단을 나누는 ‘\n’과 같은 기호들과 문장의 끝맺음을 나타내는 토큰과 같은 레이아웃 정보들은 제외하고, OCR 모델에서 인식한 텍스트 및 수식을 기반으로 평가를 수행하였다.

4.2 실험 결과


표 2. 전체 모델과 데이터셋에 대한 성능, 영어에 비한 성능 증감을 괄호안에 표기하였음.

Model		Easy OCR	Paddle OCR	Tesseract	Keras OCR	PORORO
Expression Only						
BLEU	en	0.47	0.26	0.47	0.11	0.27
	ko	0.48(+0.01)	0.13(-0.13)	0.11(-0.36)	-	0.28(+0.1)
PopEval	en	0.80	0.74	0.80	0.53	0.69
	ko	0.80	0.58(-0.16)	0.43(-0.37)	-	0.70(+0.1)
ROUGE-2	en	0.10	0.02	0.09	0.00	0.07
	ko	0.11(+0.01)	0.01(-0.01)	0.00(-0.09)	-	0.07
Text Only						
BLEU	en	0.68	0.90	0.86	0.77	0.85
	ko	0.62(-0.06)	0.21(-0.69)	0.40(-0.46)	-	0.85
PopEval	en	0.87	0.97	0.95	0.94	0.95
	ko	0.85(-0.02)	0.75(-0.22)	0.68(-0.27)	-	0.94(-0.01)
ROUGE-2	en	0.26	0.78	0.62	0.19	0.66
	ko	0.24(-0.02)	0.00(-0.78)	0.35(-0.27)	-	0.70(+0.04)
Expression and Text Mixed						
BLEU	en	0.62	0.49	0.70	0.55	0.70
	ko	0.55(-0.07)	0.16(-0.33)	0.34(-0.36)	-	0.59(-0.11)
PopEval	en	0.85	0.77	0.89	0.82	0.89
	ko	0.83(-0.02)	0.66(-0.11)	0.63(-0.26)	-	0.84(-0.05)
ROUGE-2	en	0.19	0.42	0.34	0.11	0.42
	ko	0.17(-0.02)	0.00(-0.42)	0.16(-0.18)	-	0.38(-0.04)


실험 결과, 대부분의 모델에서 영어에 비해 한국어 인식 성능이 전반적으로 낮은 경향을 보였으며, 특히 수식과 일반 텍스트가 혼합된 경우, 한국어 인식 성능은 더욱 낮아지는 경향을 보였다. 이는 표 2를 통해 확인할 수 있다. 해당 표는 구축한 전체 테

1) <https://github.com/JaidedAI/EasyOCR.git>
2) <https://packages.ubuntu.com/focal/fonts-nanum>


3) <https://github.com/faustomorales/keras-ocr.git>
4) <https://github.com/kakaobrain/pororo.git>



(a) 수식 데이터에 대한 한국어와 영어 PopEval 성능



(b) 텍스트 데이터에 대한 한국어와 영어 PopEval 성능



(c) 텍스트+수식 데이터에 대한 한국어와 영어 PopEval 성능

그림 3. 각각의 데이터에 대한 모델들의 PopEval 성능

스트 데이터셋에 대한 각 모델의 성능을 측정한 것으로, 영어에 비해 성능 증감을 괄호안에 표기하였으며, KerasOCR은 한글을 지원하지 않아 -로 표기하였다.

국내에서 개발한 CRAFT를 글자 검출 엔진으로 활용하는 EasyOCR과 국내에서 개발된 PORORO는 영어와 한국어 인식 성능이 상대적으로 유사하게 나타났다. 이러한 결과는 다른 모델들에 비해 다량의 한국어 데이터가 사용되었고, 사용된 알고리즘이 한글 인식에 적합한 것으로 추정된다. 그러나 두 모델 역시 수식과 텍스트가 혼합된 경우, 전반적으로 텍스트만 포함된 경우보다 인식 성능이 더 낮은 경향을 보였다. 이러한 경향도 그림 3을 통해 확인할 수 있다.

이는 수식과 텍스트가 혼용되어 있는 경우 OCR 모델의 인식 성능에 악영향을 줄 수 있음을 시사하며, 우리는 이를 해결하기 위해 수식 검출 태스크 및 데이터셋의 필요함과 중요성을 강조한다.

5. 결론

본 연구에서는 수식 검출을 위한 데이터셋을 구축하고 이를 활용하여 다양한 OCR 모델의 성능을 평가하였다. 실험 결과, 대부분의 모델에서 영어보다 한국어의 인식 성능이 저하되는 경향을 보였으며, 특히 수식과 텍스트가 혼합된 경우 그 성능 저하는 더욱 두드러졌다. 특히, 한국어와 수식의 혼합 인식에서 성능 저하가 발생한 점은 교육용 AI에 있어 상당한 걸림돌이 될 수 있다. 따라서, 본 연구는 이러한 한계를 극복하기 위해 수식 검출에 특화된 데이터셋을 제안하며 수식 검출 태스크의 필요성을 제안한다.

향후 연구로는 보다 많은 종류의 수식을 포함하여 교재와 비슷한 형식의 데이터셋을 구축하고, 다양한 언어와 레이아웃에서 일관된 성능을 보이는 모델 개발을 수행할 예정이다.

참고 문헌

- [1] W. Zhao, L. Gao, Z. Yan, S. Peng, L. Du, and Z. Zhang, "Handwritten mathematical expression recognition with bidirectionally trained transformer," in *ICDAR*, 2021.
- [2] Y. Baek, B. Lee, D. Han, S. Yun, and H. Lee, "Character region awareness for text detection," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 9365–9374, 2019.
- [3] R. Smith, "An overview of the tesseract ocr engine," in *Ninth international conference on document analysis and recognition (ICDAR 2007)*, vol. 2, pp. 629–633, IEEE, 2007.
- [4] Y. Du, C. Li, R. Guo, X. Yin, W. Liu, J. Zhou, Y. Bai, Z. Yu, Y. Yang, Q. Dang, *et al.*, "Pp-ocr: A practical ultra lightweight ocr system," *arXiv preprint arXiv:2009.09941*, 2020.
- [5] Y. Deng, A. Kanervisto, J. Ling, and A. M. Rush, "Image-to-markup generation with coarse-to-fine attention," in *International Conference on Machine Learning*, pp. 980–989, PMLR, 2017.
- [6] H. Mouchère, C. Viard-Gaudin, R. Zanibbi, and U. Garain, "Icfhr 2014 competition on recognition of on-line handwritten mathematical expressions (crohme 2014)," in *2014 14th International Conference on Frontiers in Handwriting Recognition*, pp. 791–796, 2014.
- [7] H.-S. Lee, Y. Yoon, P. H. Jang, and C. Choi, "Popeval: A character-level approach to end-to-end evaluation compatible with word-level benchmark dataset," in *2019 International Conference on Document Analysis and Recognition (ICDAR)*, pp. 1207–1213, IEEE, 2019.