

한글문서(HWP) 인식 데이터 구축에서 사람과 에이전트의 협업 구조 평가

허인범, 정상근[†]
충남대학교 컴퓨터공학과

{inbum, hugmanskj}@gmail.com

Evaluating Human-Agent Collaboration Structures for HWP Document Recognition Data Construction

Inbum Heo, Sangkeun Jung
Department of Computer Science & Engineering

요약

대형 언어 모델(LLM)의 발전으로 OCR, 문서 레이아웃 분석(DLA), 정보 추출 등 문서 AI의 활용 범위가 공공 업무 환경으로 확대되고 있다. 그러나 국내 공공기관에서 널리 사용되는 HWP 문서는 범용 문서 처리 도구 및 LLM이 직접 처리하기 어려운 형식으로, 실제 활용을 위해서는 별도의 데이터 구축 과정이 필요하다. 본 연구는 공공기관 HWP 문서를 대상으로 문서 수집, 디지털화, 최종 검토로 구성된 데이터 구축 파이프라인을 정의하고, 사람과 에이전트의 역할 조합에 따른 여섯 가지 조건을 비교 분석한다. 실험 결과, 에이전트 단독 수행은 가장 높은 시간 효율을 보였으나 품질과 안정성 측면에서 한계를 보였다. 반면, 에이전트가 수행하고 사람이 검수하는 방식은 자동화의 효율성을 유지하면서 최종 데이터 품질을 효과적으로 보완하였다. 본 연구는 HWP 기반 문서 AI 데이터 구축에서 사람과 에이전트의 역할 분담 효과를 정량적으로 분석하고, 에이전트 수행 후 사람 검수가 품질과 효율성을 균형 있게 달성하는 가장 효과적인 협업 구조임을 확인하였다.

1. 서론

문서 인식 기술(Document AI)은 OCR, 문서 레이아웃 분석(DLA), 정보 추출 등을 통해 문서를 기계가 처리 가능한 데이터로 변환하는 핵심 기술이다 [1, 2]. 그러나 국내 공공기관에서 널리 사용되는 HWP 문서는 PDF와 달리 범용 문서 처리 도구나 LLM 기반 시스템이 직접 다루기 어렵고, 변환 과정에서 구조 정보가 손실될 수 있다. 따라서 HWP 기반 문서 AI를 위해서는 문서 수집, 디지털화, 검토로 이어지는 별도의 데이터 구축 과정이 필요하다.

최근 LLM 및 VLM 기반 에이전트는 이러한 반복적 데이터 구축 과정을 자동화할 수 있는 대안으로 주목받고 있다 [3]. 에이전트는 문서 탐색, 변환, 파싱, 검토 작업을 자율적으로 수행할 수 있어 시간과 인력 비용을 줄일 가능성이 있다. 그러나 에이전트가 사람을 어느 정도 대체할 수 있는지, 그리고 어떤 조건에서 사람의 역할이 필요한지는 충분히 검증되지 않았다.

이에 본 연구는 공공기관 HWP 문서를 대상으로 문서 AI 데이터 구축 과정에서 사람과 에이전트의 역할을 비교 분석한다. 파이프라인은 문서 수집, 문서 디지털화, 최종 검토의 세 단계로 구성되며, 수행 주체와 검수 주체의 조합에 따라 여섯 가지 조건을 설계하였다. 구체적으로 전 과정을 사람 또는 에이전트가 단독으로 수행하는 조건, 에이전트 수행 결과를 사람 또는 에이전트가 검수하는 조건, 사람 수행 결과를 사람 또는 에이전트가 검수하는 조건을 비교한다.




그림 1: 문서 AI 데이터 구축 파이프라인

실험 결과, 에이전트 단독 수행은 가장 높은 시간 효율을 보였으나 최종 데이터 품질에서는 한계가 확인되었다. 반면, 에이전트가 수행하고 사람이 검수하는 구조는 자동화의 효율성을 유지하면서 품질 저하를 효과적으로 보완하였다. 이는 HWP 문서 AI 데이터 구축에서 완전 자동화보다 사람 검수를 결합한 협업형 파이프라인이 더 현실적인 대안임을 시사한다.

2. 관련 연구

LLM 기반 데이터 구축 자동화 최근에는 LLM 기반 에이전트를 활용해 데이터 수집, 문서 처리, 주석 생성을 자동화하려는 시도가 늘고 있다 [4]. 이러한 방식은 확장성과 비용 측면에서 장점이 있지만, 복잡한 작업에서는 오류 누적과 출력 불안정성이 발생할 수 있다. 또한 일부 연구는 동일 과업에서도 에이전트가 사람보다 더 많은 단계와 상호작용을 필요로 할 수 있음을 보여주며, 자동화의 효율성과 신뢰성을 함께 검토해야 함을 시사한다 [5].

[†] 교신저자 (Corresponding author)

* 본 연구는 과학기술정보통신부 및 한국연구재단의 중견연구지원사업의 연구 결과로 수행되었음(RS-2025-0055621731482092640101)

표 1: HWP 문서 인식 데이터 200건에 대한 단계별 성능-비용 비교.
 괄호 안의 값은 검수 미적용 기준 대비 변화량이며, 파란색은 데이터 품질 향상(오류 감소), 붉은색은 시간 증가를 의미한다.

협업구조	문서 수집		문서 디지털화				최종 검토		
	오류율 ↓	시간 ↓	IoU ↑	라벨 정확도 ↑	CER ↓	시간 ↓	오류 검출률 ↑	F1 ↑	시간 ↓
에이전트 수행	3.5%	18	74.6	79.1	5.26%	54	31.0%	0.34	17
에이전트 수행-사람 검수	2.0% (-1.5%)	24 (+6)	88.9 (+14.3)	90.8 (+11.7)	1.92% (-3.34%)	85 (+31)	70.7% (+39.7%)	0.72 (+0.38)	20 (+3)
에이전트 수행-에이전트 검수	2.0% (-1.5%)	31 (+13)	84.7 (+10.1)	85.4 (+6.3)	2.42% (-2.84%)	76 (+22)	58.4% (+27.4%)	0.59 (+0.25)	15 (-2)
사람 수행	1.0%	42	95.9	99.2	0.74%	108	71.1%	0.74	35
사람 수행-사람 검수	0.0% (-1.0%)	59 (+17)	99.1 (+3.2)	99.4 (+0.2)	0.61% (-0.13%)	131 (+23)	78.1% (+7.0%)	0.81 (+0.07)	36 (+1)
사람 수행-에이전트 검수	0.5% (-0.5%)	45 (+3)	96.2 (+0.3)	99.4 (+0.2)	0.70% (-0.04%)	121 (+13)	72.5% (+1.4%)	0.75 (+0.01)	38 (+3)

Human-in-the-loop 완전 자동화의 한계를 보완하기 위해, 최근에는 사람의 개입을 결합한 **human-in-the-loop** 방식이 주목받고 있다. 이 방식은 사람이 전 과정을 직접 수행하기보다, 오류에 민감한 단계에 선택적으로 개입해 품질과 효율성의 균형을 확보하는 데 목적이 있다 [6, 7]. 따라서 핵심은 사람의 개입 여부 자체보다, 어느 단계에서 어떤 방식으로 개입하는가에 있다.

이에 본 연구는 국내 공공기관 HWP 문서를 대상으로, 문서 수집, 디지털화, 검수로 이루어진 데이터 구축 파이프라인 전반에서 수행 주체와 검수 방식의 조합을 체계적으로 비교한다. 이를 통해 에이전트 기반 자동화가 어느 수준까지 가능하며, 어떤 단계에서 사람의 개입이 여전히 필요한지를 실증적으로 분석한다.

3. 문서 AI 데이터 구축 파이프라인

본 연구는 문서 AI 데이터 구축 과정을 **문서 수집**, **문서 디지털화**, **최종 검토**의 세 단계로 구성된 파이프라인으로 정의한다. 각 조건에서 사람과 에이전트는 동일한 입력과 동일한 목표 하에서 해당 파이프라인을 수행한다.

3.1 문서 수집 단계

문서 수집 단계에서는 웹 또는 공공 저장소로부터 실험 대상 HWP 문서를 탐색하고 확보한다. 본 연구에서는 경기도 뉴스포털¹과 한국교육과정평가원²의 공공 웹사이트를 대상으로, 각 100건씩 총 200건의 HWP 문서를 수집하였다. 에이전트 기반 방식에서는 웹 구조를 분석하여 목표 문서를 자동으로 탐색하고 수집하였다. 이 단계의 산출물은 원본 HWP 파일이며, 주요 실패 유형은 문서 누락, 비대상 파일 수집, 다운로드 실패로 정의한다.

3.2 문서 디지털화 단계

문서 디지털화 단계에서는 수집된 HWP 문서를 문서 AI 학습 및 평가에 활용할 수 있는 구조화된 데이터로 변환한다. 본 연구에서 생성하는 디지털 데이터는 각 영역의 위치를 나타내는 *bbox*,

영역의 범주를 나타내는 *label*, 그리고 해당 영역의 텍스트를 나타내는 *text*로 구성된다. 이를 위해 먼저 HWP 문서를 PDF로 변환한 뒤, LLM을 활용하여 문서 디지털화를 수행한다. 따라서 본 단계는 단순한 OCR을 넘어, 문서 구조 인식과 텍스트 추출을 통합적으로 수행하는 문서 디지털화 과정으로 볼 수 있다.

3.3 단계별 검수

본 연구에서 검수는 문서 수집과 문서 디지털화 이후에 선택적으로 수행되는 중간 품질 관리 과정이다. 검수는 수행 결과가 다음 단계로 전달되기 전에 오류를 탐지하고 수정하는 역할을 한다. 검수 주체는 조건에 따라 사람 또는 에이전트로 설정되며, 검수가 없는 조건에서는 수행 결과가 별도의 확인 없이 다음 단계로 전달된다. 이를 통해 본 연구는 단순한 수행 주체 비교를 넘어, 검수 여부와 검수 주체가 데이터 구축 결과에 미치는 영향을 함께 분석한다.

3.4 최종 검토 단계

최종 검토 단계에서는 문서 디지털화 결과가 목표 포맷에 부합하는지, 그리고 문서의 실제 내용과 의미적으로 일치하는지를 확인한다. 또한 오류가 발견될 경우 해당 결과를 수정하거나 재수행을 요청한다. 구체적으로는 누락된 영역, 잘못된 구조 라벨, 텍스트 인식 오류, 포맷 위반 등을 점검한다. 이 단계의 최종 산출물은 검토를 거쳐 확정된 문서 AI 데이터이며, 본 연구에서는 이를 기준으로 품질, 효율성, 안정성을 평가한다.

4. 실험 및 결과 분석

4.1 실험 설계

본 연구는 공공기관 HWP 문서 200건을 대상으로, 문서 AI 데이터 구축 파이프라인에서 수행 주체와 검수 주체의 조합에 따른 차이를 비교하였다.

전체 파이프라인은 수집, 디지털화, 최종 검토의 세 단계로 구성되며, 비교 조건은 **사람 수행**, **에이전트 수행**, **에이전트 수행-사람 검수**, **에이전트 수행-에이전트 검수**, **사람 수행-사람 검수**,

1) gnews.gg.go.kr
 2) kice.re.kr

사람 수행-에이전트 검수의 여섯 가지이다. 에이전트가 포함된 조건에서는 모두 동일한 기반 모델인 GPT-5.4 [8]를 사용하였다.

4.2 실험 결과 및 분석

표 1와 표 2는 여섯 가지 조건의 단계별 성능과 최종 결과를 보여준다. 전체적으로 에이전트 단독 수행은 가장 높은 시간 효율성을 보였지만, 데이터 품질과 안정성에서는 뚜렷한 한계를 보였다. 반면 에이전트 수행 후 사람 검수를 결합한 구조는 품질과 효율성의 균형 측면에서 가장 효과적인 조건으로 확인되었다.

완전 자동화의 효율성과 한계 에이전트 수행은 전체 조건 중 가장 짧은 시간에 데이터를 구축할 수 있었으나, 품질 지표에서는 사람 수행 대비 낮은 성능을 보였다. 이는 에이전트가 반복적이고 절차적인 작업을 빠르게 수행하는 데에는 강점이 있지만, HWP 문서의 구조적 예외와 오류 상황을 안정적으로 처리하는 데에는 한계가 있음을 의미한다.

데이터 검수 주체에 따른 품질 검수 구조를 추가하면 에이전트 수행의 품질 저하를 완화할 수 있었지만, 그 효과는 검수 주체에 따라 달랐다. 특히 에이전트 수행-사람 검수는 에이전트 단독 수행보다 데이터 품질과 오류 검출률을 크게 개선하였다. 반면 에이전트 수행-에이전트 검수는 일부 개선은 보였으나 사람 검수 수준에는 미치지 못했다.

품질-효율 trade-off 가장 높은 품질은 사람 수행-사람 검수에서 나타났지만, 실제 활용 관점에서는 품질과 소요 시간의 균형이 중요하다. 에이전트 수행-사람 검수는 사람 단독 수행보다 짧은 시간 안에 비교적 높은 품질을 확보하였다. 이는 HWP 문서 인식 데이터 구축에서 완전 자동화보다, 에이전트의 처리 효율성과 사람 검수의 신뢰성을 결합한 협업 구조가 더 실용적인 전략임을 보여준다.

5. 결론

본 연구는 공공기관 HWP 문서를 대상으로, 문서 AI 데이터 구축 파이프라인에서 사람과 에이전트의 역할 조합에 따른 성능 차이를 비교하였다. 실험 결과, 에이전트 수행은 가장 높은 효율성을 보였지만 품질 저하가 컸으며, 에이전트 수행-사람 검수는 시간 절감 효과를 유지하면서도 품질을 크게 회복하는 가장 현실적인 절충안으로 나타났다. 반면 에이전트 수행-에이전트 검수의 개선 효과는 제한적이었다.

이는 문서 AI 데이터 구축에서 중요한 것이 완전 자동화 자체보다, 에이전트의 효율성과 사람의 판단을 어떻게 결합할 것인가에 있음을 보여준다. 특히 공공기관 HWP 문서와 같이 예외가 많은 환경에서는, 현 시점에서 사람 검수를 포함한 hybrid 방식이 가장 실용적인 전략임을 확인하였다.

표 2: 최종 데이터셋 품질 및 총 소요시간 비교.
Bold는 각 지표의 최적값을, **파란색**은 성능 대비 시간 효율이 가장 높은 조건을 나타낸다.

조건	IoU↑	라벨↑	CER↓	총 시간↓
에이전트 수행	74.6	79.1	5.26%	89
에이전트 수행-사람 검수	88.9	90.8	1.92%	129
에이전트 수행-에이전트 검수	84.7	85.4	2.42%	112
사람 수행	95.9	99.2	0.74%	185
사람 수행-사람 검수	99.1	99.4	0.61%	226
사람 수행-에이전트 검수	96.2	99.4	0.70%	204

참고 문헌

[1] W. Wang, H. Hu, Z. Zhang, Z. Li, H. Shao, and D. Dahlmeier, “Document intelligence in the era of large language models: A survey,” *arXiv preprint arXiv:2510.13366*, 2025.

[2] W. Ke, Y. Zheng, Y. Li, H. Xu, D. Nie, P. Wang, and Y. He, “Large language models in document intelligence: A comprehensive survey, recent advances, challenges, and future trends,” *ACM Transactions on Information Systems*, vol. 44, no. 1, pp. 1–64, 2025.

[3] T. Xie, D. Zhang, J. Chen, X. Li, S. Zhao, R. Cao, T. J. Hua, Z. Cheng, D. Shin, F. Lei, *et al.*, “Osworld: Benchmarking multimodal agents for open-ended tasks in real computer environments,” *Advances in Neural Information Processing Systems*, vol. 37, pp. 52040–52094, 2024.

[4] Z. Tan, D. Li, S. Wang, A. Beigi, B. Jiang, A. Bhattacharjee, M. Karami, J. Li, L. Cheng, and H. Liu, “Large language models for data annotation and synthesis: A survey,” in *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, pp. 930–957, 2024.

[5] X. Liu, H. Yu, H. Zhang, Y. Xu, X. Lei, H. Lai, Y. Gu, H. Ding, K. Men, K. Yang, *et al.*, “Agentbench: Evaluating llms as agents,” *arXiv preprint arXiv:2308.03688*, 2023.

[6] S. Budd, E. C. Robinson, and B. Kainz, “A survey on active learning and human-in-the-loop deep learning for medical image analysis,” *Medical image analysis*, vol. 71, p. 102062, 2021.

[7] H. Schroeder, D. Roy, and J. Kabbara, “Just put a human in the loop? investigating LLM-assisted annotation for subjective tasks,” in *Findings of the Association for Computational Linguistics: ACL 2025* (W. Che, J. Nabende, E. Shutova, and M. T. Pilehvar, eds.), (Vienna, Austria), Association for Computational Linguistics, July 2025.

[8] OpenAI, “GPT-5.4 technical report,” tech. rep., OpenAI, March 2026. Released March 5, 2026.