

협상 과제에서 LLM 에이전트의 의사결정 구조와 협상 성향에 따른 성능 비교

김채연^o, 허인범, 정상근^{*}

충남대학교 인공지능학과, 충남대학교 컴퓨터융합학부

{0126key, inbum10222, hugmanskj}@gmail.com

A Comparative Analysis of LLM Agent Organizational Structures in Negotiation Settings

Chaeyeon Kim, Inbum Heo, Sangkeun Jung^{*}

Chungnam National University, Department of Artificial Intelligence, Chungnam National University, Department of Computer Science and Engineering

요약

협상은 자연어 상호작용과 전략적 의사결정이 결합된 대표적인 언어 기반 의사결정 과제이다. 최근 대형 언어모델(LLM)이 협상 주체로 활용되면서, LLM의 협상에 대한 연구가 활발히 이루어지고 있다. 그러나 동일한 기반 모델을 서로 다른 에이전트 구조로 구성했을 때 성능과 비용 효율성이 어떻게 달라지는지는 충분히 분석되지 않았다. 본 연구는 *Deal or No Deal* 기반 2,236개 협상 시나리오에서 동일한 LLM을 여섯 가지 협상 에이전트 구조로 구현하고, 동일한 상대 에이전트 조건에서 성능과 비용 효율성을 비교한다. 실험 결과, 확장 구조가 항상 성능 향상으로 이어지는 않았다. 이는 비교적 단순한 협상 과제에서 LLM 협상 에이전트를 설계할 때, 내부 구조의 복잡성보다 협상 목표에 맞는 persona 지시와 성능-비용 균형이 더 중요한 설계 요소일 수 있음을 시사한다.

1. 서론

협상(negotiation)은 언어적 소통을 통해 전략적 의사결정을 조율하는 대표적인 상호작용 과제이다. 최근 대형 언어모델(LLM)의 자연어 이해 및 생성 능력이 향상되면서, LLM을 협상 주체로 활용하는 연구가 활발히 진행되고 있다. 그러나 기존 LLM 협상 연구는 주로 개별 LLM의 전략 개선이나 성능 향상에 초점을 두고 있어, 협상 에이전트를 어떤 구조로 조직화하느냐에 따른 성능 차이를 체계적으로 분석하는 데에는 한계가 있다. [1, 2, 3].

실제 협상에서는 참여자들이 상황에 따라 다양한 전략을 구사하고 역할을 분담하며 의사결정을 수행한다. 이와 유사하게, 협상 에이전트 역시 단일 에이전트부터 복수 에이전트 조합까지 다양한 방식으로 구성될 수 있으며, 이러한 구성 차이는 응답 품질 뿐만 아니라 비용과 시간에도 영향을 줄 수 있다.

본 연구는 LLM 기반 협상 에이전트의 조직화 방식에 따른 성능을 체계적으로 분석한다. 구체적으로, 단일 의사결정 구조(Single-Agent) 3개, 확장 의사결정 구조(Multi-Agent) 3개로 구성된 총 여섯 가지 조직화 방식을 설계하고, 합의율(agreement rate), 보상(Score), Pareto optimality, 비용(cost), 응답 지연 시간(latency)의 관점에서 각 방식의 성능과 특성을 비교한다. 이를 통해 협상 에이전트의 조직화 방식에 따라 나타나는 각 방식의 특성과 차이를 실증적으로 살펴본다.

본 연구의 주요 기여는 다음과 같다:

- 협상 에이전트의 조직화 방식을 기준으로 총 6가지 협상 구조를 설계하고, 이를 비교·분석한다.
- 조직화 방식에 따라 나타나는 협상 성능과 효율성의 차이를 다양한 관점에서 정량적으로 분석한다.
- 성능 지표와 비용 지표 간의 trade-off를 분석하여, 협상 에이전트 구성 방식별 특성과 한계를 논의한다.

2. 관련연구

2.1 협상 데이터셋

자동 협상 대화 연구는 서로 다른 보상 구조를 가진 참여자들이 자연어 대화를 통해 합의안을 도출하는 과제로 발전해 왔다. 대표적으로 *Deal or No Deal* 환경과 end-to-end 협상 모델이 제안되었으며, 이를 통해 자연어 상호작용과 보상 최적화를 함께 다룰 수 있는 대표적인 협상 벤치마크가 구축되었다 [4]. 이후 전략 결정과 발화 생성을 분리하는 모듈식 접근이 제안되어 협상 과정의 구조적 분해 가능성이 논의되었고 [5], 보다 풍부한 상호작용과 설득 전략 분석이 가능한 *CaSiNo* 데이터셋이 제안되면서 협상 연구의 현실성과 다양성이 확장되었다 [6].

2.2 LLM 기반 협상 에이전트 및 조직화

최근 연구는 LLM의 협상 능력을 문맥 이해, Theory-of-Mind, 전략적 추론, 의사소통 등 다양한 측면에서 평가하고 [7], 가격 협상과 같은 비대칭 불완전정보 환경에서 협상 벤치마크와 성능 향상 기법을 제안해 왔다 [8]. 또한 상대의 성향을 추정하여 협상 전략을 조정하는 personality modeling [9], 그리고 self-play, tool-integrated optimization, dual-process negotiation agent와 같은 협상 성능 향상 접근이 제안되었다. 한편 보다 일반적인 관점에서는 self-consistency, AutoGen, ChatDev와 같이 복수 후보 생성, 역할 분담, 다중 에이전트 상호작용을 활용하는 다양한 조직화 방식 또한 활발히 연구되어 왔다 [10, 11, 12].

그러나 이러한 조직화 방식이 협상 과제에서 성능과 비용의 trade-off에 어떠한 영향을 미치는지는 아직 충분히 비교·분석되지 않았다. 이에 본 연구는 동일한 기반 LLM과 동일한 협상 환경에서 다양한 조직화 구조를 비교함으로써, 이러한 차이를 체계적으로 분석한다.

^{*} 본 연구는 과학기술정보통신부 및 한국연구재단의 중견연구지원사업의 연구결과로 수행되었음(RS-2025-0055621731482092640101)




그림 1: 협상 에이전트의 6가지 조직화 방식

3. 협상 에이전트 조직화 설계 및 평가

3.1 협상 환경 및 과제 설정

본 연구의 협상 과제는 *Deal or No Deal* 환경 [4]을 기반으로 한다. 각 시나리오는 물건의 개수와 에이전트별 물건 가치로 구성되며, 각 에이전트는 자신의 가치 정보만을 바탕으로 상대와 대화하며 협상을 수행한다.

3.2 협상 에이전트 조직화

협상 에이전트의 조직화 방식을 단일 의사결정 구조(Single-Agent)와 확장 의사결정 구조(Multi-Agent)로 구분한다.

비교 대상 6개 조직화 방식의 내부 의사결정 흐름은 그림 1에 제시하였다. 각 구조는 동일한 협상 상태를 입력으로 받아 협상 발화를 생성하지만, 직접 생성, 후보 선택, 역할 분해, persona 통합 등 최종 발화를 도출하는 방식에서 차이를 가진다.

3.2.1 단일 의사결정 구조

단일 의사결정 구조는 하나의 에이전트가 협상을 수행하는 구조로, 본 연구에서는 *Single Negotiation Agent*, *Competitive Single Agent*, *Cooperative Single Agent*의 세 가지 방식으로 구성된다.

1) Single Agent 단일 에이전트(모델)가 협상 발화를 생성하는 가장 기본적인 구조이다.

2) Competitive Single Agent 자신의 보상 극대화를 우선 목표로 삼도록 설계한 단일 에이전트 구조이다. 상대와의 합의 자체보다 자신의 점수를 높이는 방향으로 발화와 제안을 조정하며, 공격적이거나 양보를 최소화하는 협상 행동을 보일 수 있다.

3) Cooperative Single Agent 상호 수용 가능한 합의를 우선시하도록 설계한 단일 에이전트 구조이다. 자신의 최대 보상보다 안정적인 합의 도출 가능성을 중시하며, 보다 완화된 표현과 타협 지향적 전략을 보일 수 있다.

3.2.2 확장 의사결정 구조

확장 의사결정 구조는 복수의 LLM 호출, 후보 발화 선택, 역할 분해, 또는 persona ensemble을 활용하여 최종 협상 발화를 구성하는 방식이다. 본 연구에서는 *Self-Consistency Agent*, *Role-Based Team Agent*, *Multi-Persona Aggregation Agent*의 세 가지 방식으로 구성된다.

4) Self-Consistency Agent 동일한 협상 상태에 대해 후보 발화를 생성한 뒤, 선택 에이전트가 최종 응답을 결정하는 구조이다. 본 연구에서는 동일한 프롬프트로 $K = 3$ 개의 후보를 생성하고 이 중 하나를 최종 발화로 선택한다.

5) Role-Based Team Agent 협상 과정을 역할별로 분리한 구조로, 본 연구에서는 *planner*, *speaker*, *checker*의 3단계로 구성한다. *planner*는 목표와 전략을 수립하고, *speaker*는 이를 발화로 구체화하며, *checker*는 생성된 발화의 전략적 적절성을 점검한다.

6) Multi-Persona Team Agent 상반된 성향을 지닌 두 에이전트의 출력을 선택하는 구조이다. *Competitive persona*와 *Cooperative persona*가 각각 후보 발화를 생성하고, *Aggregator*가 이를 비교해 현재 협상 맥락에 적합한 최종 협상 발화를 선택한다.

4. 실험 및 결과 분석

4.1 실험 설정

본 실험은 OpenRouter¹ 기반의 openai/gpt-4.1-mini 모델을 사용하였다. 모든 평가 대상 에이전트는 동일한 상대 에이전트와 협상하였으며, 상대 에이전트는 동일한 모델을 사용하는 *Single Agent* 구조로 고정하였다. 각 조직화 방식은 *Deal or No Deal*의 동일한 2,236개 item-count/value 시나리오를 사용했으며, 시나리오의 순서 또한 모든 실험에서 동일하게 유지하였다.

1) <https://openrouter.ai/>

표 1: GPT-4.1-Mini 기반 협상 에이전트 구성 방식 비교.
Score 열에서 앞의 값은 평가 대상 에이전트, 뒤의 값은 고정된 상대 에이전트의 값을 의미한다.

Category	Architecture	Agreement Rate (%) ↑	Score (All) ↑	Score (Agreed) ↑	Pareto Optimality (%) ↑	Cost (USD/ep.) ↓	Latency (s/ep.) ↓
Single-Agent	Single Agent	33.5	2.42 / 2.44	7.23 / 7.27	73.4	0.0064	16.2
	Competitive Single Agent	27.3	2.00 / 1.93	7.34 / 7.05	70.8	0.0068	16.2
	Cooperative Single Agent	34.3	2.45 / 2.40	7.15 / 7.00	67.7	0.0061	13.6
Multi-Agent	Self-Consistency	33.0	2.40 / 2.41	7.27 / 7.32	77.6	0.0105	27.0
	Role-Based Team	28.2	1.46 / 2.08	5.17 / 7.39	45.3	0.0197	36.0
	Multi-Persona Team	32.5	2.23 / 2.45	6.88 / 7.55	71.3	0.0087	21.1

4.2 평가 지표

평가는 Agreement Rate, Score-All, Score-Agreed, Pareto Optimality, Cost, Latency의 6가지 지표를 사용하였다. Agreement Rate는 전체 협상 중 합의가 성립한 비율을 의미하며, Score-All과 Score-Agreed는 각각 전체 협상 및 합의된 협상에서의 평균 보상을 나타낸다. Pareto Optimality는 합의된 사례 중 Pareto optimal한 합의의 비율로 정의하였으며, Cost와 Latency는 협상당 전체 LLM 호출 비용과 응답 시간의 평균값으로 측정하였다.

4.3 실험 결과 분석

표 1를 바탕으로, 각 조직화 방식이 협상 성능과 비용 효율성에 미치는 영향을 세 가지 관점에서 분석하였다.

어떤 구성 방식이 가장 효과적인가? 실험 결과, 복잡한 구조가 항상 더 높은 협상 성능을 보이지는 않았다. 관측값 기준으로는 Cooperative Single Agent가 Agreement Rate 34.3%와 Score (All) 2.45로 가장 높은 값을 보였다. 이는 합의 가능성을 고려하는 것이 평균 성과에 유리하게 작용할 가능성을 시사한다.

구성 방식별 성능-효율 trade-off는 어떻게 나타나는가? 비용과 latency를 함께 고려하면, Cooperative Single Agent는 가장 낮은 비용과 latency에서 가장 높은 Score (All)을 보였다. 반면 Self-Consistency Agent는 합의가 성립한 경우의 Pareto optimality가 77.6%로 가장 높았으나, 전체 episode 기준 Pareto-efficient agreement 비율에서는 Single Agent와의 차이가 상대적으로 작다. 또한 후보 생성, 선택 과정으로 인해 비용과 latency가 증가하였다. Role-Based Team Agent는 높은 비용임에도 성능 개선으로 이어지지 않았다.

각 구성 방식의 특징은 무엇인가? Competitive Single Agent는 합의 시 높은 보상을 보였지만 합의율이 낮아 전체 성능은 감소, Cooperative Single Agent는 합의율과 평균 보상에서 안정적인 성능을 보였다. Self-Consistency Agent는 합의된 사례에서 가장 높은 Pareto Optimality를 보였으나, 후보 생성과 선택 과정으로 인해 비용이 증가하였고, Multi-Persona Aggregation Agent는 단순 결합만으로는 성능 향상이 보장되지 않았다.

5. 결론

본 연구는 협상 환경에서 동일한 LLM을 여섯 가지 에이전트 구성 방식으로 구현하고, 성능과 비용 효율성을 비교하였다. 실험 결과, 추가적인 내부 호출이나 역할 분해를 포함한 확장 구조가 항상 더 높은 성능으로 이어지는 않았으며, 관측 평균 기준 Cooperative Single Agent가 비용 대비 안정적인 성능을 보였다. 또한 Self-Consistency Agent는 Pareto optimality 측면에서 강점을 보였으나 비용과 응답 지연 시간이 증가하였다. 이러한 결과는 LLM 기반 협상 에이전트 설계에서 내부 구조의 복잡성이 항상 성능 향상으로 이어지는 않으며, 협상 목표와 성능-비용 trade-off를 함께 고려해야 함을 시사한다.

참고 문헌

- [1] A. Liao et al., "Efficacy of Language Model Self-Play in Non-Zero-Sum Games," arXiv:2406.18872, 2024.
- [2] D. Kwon et al., "ASTRA: A Negotiation Agent with Adaptive and Strategic Reasoning via Tool-integrated Action for Dynamic Offer Optimization," in *Proc. EMNLP*, 2025, pp. 16217–16238.
- [3] Y. Liu et al., "A Dual-Mind Framework for Strategic and Expressive Negotiation Agent," in *Proc. ACL*, 2025, pp. 23840–23860.
- [4] M. Lewis et al., "Deal or No Deal? End-to-End Learning of Negotiation Dialogues," in *Proc. EMNLP*, 2017, pp. 2443–2453.
- [5] H. He et al., "Decoupling Strategy and Generation in Negotiation Dialogues," in *Proc. EMNLP*, 2018, pp. 2333–2343.
- [6] K. Chawla et al., "CaSiNo: A Corpus of Campsite Negotiation Dialogues for Automatic Negotiation Systems," in *Proc. NAACL-HLT*, 2021, pp. 3167–3185.
- [7] D. Kwon et al., "Are LLMs Effective Negotiators? Systematic Evaluation of the Multifaceted Capabilities of LLMs in Negotiation Dialogues," in *Findings of EMNLP*, 2024, pp. 5391–5413.
- [8] T. Xia et al., "Measuring Bargaining Abilities of LLMs: A Benchmark and A Buyer-Enhancement Method," in *Findings of ACL*, 2024, pp. 3579–3602.
- [9] R. Yang et al., "Improving Dialog Systems for Negotiation with Personality Modeling," in *Proc. ACL-IJCNLP*, 2021, pp. 681–693.
- [10] X. Wang et al., "Self-Consistency Improves Chain of Thought Reasoning in Language Models," in *ICLR*, 2023.
- [11] Q. Wu et al., "AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversations," in *COLM*, 2024.
- [12] C. Qian et al., "ChatDev: Communicative Agents for Software Development," in *Proc. ACL*, 2024, pp. 15174–15186.